

**Optimización de la gestión de memoria en simuladores cuánticos mediante la
compresión de datos sin pérdida de precisión**

Daniel Adrián González Buendía

Javier Andrés Sarmiento Salazar

Trabajo de grado para optar el título de Ingeniero de Sistemas

Director

Luis Alberto Núñez Martínez

PhD en Ciencias de la Computación

Codirector

Gilberto Javier Díaz Toro

PhD en Ciencias de la Computación

Universidad Industrial de Santander

Facultad De Ingenierías Fisicomecánicas

Escuela De Ingeniería De Sistemas e Informática

Pregrado en Ingeniería de Sistemas e Informática Bucaramanga

2026

Dedicatoria

Este trabajo está dedicado a las personas que acompañaron este proceso de formación personal y profesional.

A nuestras familias.

A nuestras amistades.

A quienes hicieron posible este camino.

Contenido

Introducción	5
1. Planteamiento del problema	6
2. Objetivos	7
2.1. Objetivo general	7
2.2. Objetivos específicos	7
3. Marco teórico	8
3.1. Fundamentos de información cuántica	8
3.1.1. Qubits, espacio de estados y superposición	8
3.1.2. Entrelazamiento	10
3.1.3. Interferencia	10
3.2. Modelo de circuitos cuánticos	11
3.2.1. Evolución unitaria y compuertas cuánticas	11
3.2.2. Compuertas controladas y operaciones sobre varios qubits	12
3.2.3. Medición	13
3.3. Del modelo cuántico a su representación clásica	13
3.3.1. El vector de estado como representación computacional	13
3.3.2. Organización del vector de estado en memoria	14
3.3.3. Aplicación de compuertas sobre el arreglo de amplitudes	15
3.3.4. Consideraciones básicas de almacenamiento y acceso	17
3.4. Gestión de memoria y compresión de datos en arreglos numéricos	17
3.4.1. Gestión de memoria en simulación científica	17
3.4.2. Conceptos generales de compresión de datos	18
3.4.3. Compresión sin pérdida en datos de punto flotante	19

3.4.4.	Compresión por bloques, descompresión selectiva y caché	19
3.4.5.	Exactitud numérica e igualdad exacta	20
4.	Estado del arte	21
4.1.	Simuladores cuánticos	21
4.2.	Compresión de memoria con pérdida de precisión	22
4.3.	Compresión de memoria sin pérdida de precisión	24
4.4.	Enfoques de compresión sin pérdida para datos de punto flotante	25
4.4.1.	FPC (Burtscher & Ratanaworabhan)	26
4.4.2.	FPZIP (Lindstrom & Isenburg)	27
4.4.3.	Bitshuffle con LZ4 (Masui et al.)	27
4.4.4.	Transformación de Datos Tipados (TDT)	28
4.5.	Otros métodos de optimización de memoria	29
5.	Metodología de la investigación	30
5.1.	Diseño	31
5.2.	Implementación e integración de la estrategia	32
5.3.	Evaluación experimental	33
6.	Selección del simulador cuántico base	34
6.1.	Necesidad de seleccionar un simulador base	34
6.2.	Criterios de selección	35
6.3.	Simuladores considerados	37
6.4.	Matriz de evaluación ponderada	38
6.5.	Selección del simulador	39
7.	Selección de la biblioteca de compresión sin pérdida	40
7.1.	Necesidad de seleccionar una biblioteca de compresión	40
7.2.	Criterios de selección	40

7.3. Bibliotecas de compresión sin pérdida consideradas	42
7.4. Matriz de evaluación ponderada	43
7.5. Selección de la biblioteca de compresión	44
8. Patrones de compresibilidad en vectores de estado de algoritmos cuánticos	44
8.1. Relación entre estructura del estado y compresibilidad	44
8.2. Búsqueda de Grover: uniformidad y baja entropía	45
8.3. Transformada cuántica de Fourier: variación de fase y baja redundancia . . .	46
8.4. Algoritmo de Shor: periodicidad y concentración espectral	47
8.5. Deutsch–Jozsa y Simon: estructura y esparsidad	47
8.6. Circuitos variacionales y circuitos aleatorios: entre regularidad y alta entropía	48
8.7. Implicaciones para la compresión sin pérdida	48
9. Diseño de la arquitectura de compresión sin pérdida para simuladores tipo	
Schrödinger	49
9.1. Objetivos de diseño	52
9.2. Representación por bloques del vector de estado	52
9.3. Descompresión selectiva y estrategia de acceso	53
9.4. Caché LRU de bloques descomprimidos	54
9.5. Flujo de compresión y descompresión	56
9.6. Compromisos y parámetros de diseño	56
10. Implementación del esquema de almacenamiento comprimido basado en	
Blosc	57
10.1. Alcance de la implementación	57
10.2. Realización del esquema de almacenamiento comprimido con Blosc	58
10.3. Disposición en bloques y mapeo del vector de estado	60
10.4. Caché LRU de bloques descomprimidos	60
10.5. Acceso, actualización y ejecución de compuertas	61

10.6. Optimización específica para Grover mediante parametrización reducida . . .	64
11.Evaluación experimental y resultados	66
11.1. Diseño experimental	66
11.1.1. Estrategias comparadas	66
11.1.2. Selección de cargas de trabajo	66
11.1.3. Escala del experimento	67
11.1.4. Entorno experimental e instrumentación	67
11.1.5. Configuración de compresión	68
11.1.6. Métricas de evaluación	68
11.1.7. Verificación de exactitud numérica	69
11.1.8. Comparación complementaria para Grover	69
11.2. Resultados para Grover	70
11.2.1. Objetivo único	70
11.2.2. Multiobjetivo	71
11.2.3. Comparación complementaria con la variante optimizada	72
11.3. Resultados para QFT	74
11.3.1. Superposición periódica	74
11.3.2. Superposición de alta entropía	76
11.4. Comparación global de estrategias	78
12.Conclusiones y trabajo futuro	79
12.1. Conclusiones	79
12.2. Trabajo futuro	80
Referencias	86

Lista de figuras

1.	Metodología de investigación	31
2.	Arquitectura por bloques para la integración de compresión sin pérdida en simuladores cuánticos tipo Schrödinger	51
3.	Particionamiento abstracto del vector de estado en bloques independientes .	53
4.	Política de caché LRU para bloques	55
5.	Diagrama de clases de la implementación del backend comprimido basado en Blosc2.	59
6.	Flujo de ejecución para compuertas locales sobre un único bloque	62
7.	Flujo de ejecución para compuertas que operan entre bloques	63
8.	Flujo de persistencia diferida y escritura en backend comprimido	64

Lista de tablas

1.	Correspondencia entre estado base, amplitud e índice en memoria para un sistema de 3 qubits.	15
2.	Pares de amplitudes afectados por una compuerta de un solo qubit en un sistema de 3 qubits, mostrando qué bits permanecen fijos y cuál varía según el qubit objetivo.	16
3.	Criterios usados para la selección del simulador cuántico	36
4.	Evaluación de alternativas (escala 1–5) y total ponderado	39
5.	Criterios para la selección de bibliotecas de compresión sin pérdida	41
6.	Evaluación de bibliotecas de compresión sin pérdida (escala 1–5) y total ponderado	43
7.	Configuraciones de compresión utilizadas en toda la campaña experimental .	68
8.	Grover con objetivo único: promedios sobre las posiciones $N/8$, $N/2$ y $7N/8$	71
9.	Grover multiobjetivo con tres estados marcados	72
10.	Variante optimizada de Grover con objetivo único	73
11.	Variante optimizada de Grover multiobjetivo	74
12.	QFT con superposición periódica	76
13.	QFT con superposición de alta entropía	77
14.	Síntesis comparativa frente al almacenamiento no comprimido	78

Lista de apéndices

A. Derivación de la parametrización reducida de Grover	82
---	-----------

Glosario

Blosc2: Biblioteca de compresión por bloques utilizada en este trabajo para el almacenamiento sin pérdida

HPC: Computación de alto rendimiento (High Performance Computing)

LRU: Least Recently Used, política de reemplazo de caché basada en el uso más reciente

MPI: Message Passing Interface, estándar de comunicación para paralelismo en memoria distribuida

MPS: Matrix Product States, representación tensorial eficiente cuando el entrelazamiento del estado es limitado

OpenMP: API de paralelismo de memoria compartida para programación multihilo

QFT: Transformada Cuántica de Fourier (Quantum Fourier Transform)

ZFP: Biblioteca de compresión para arreglos de punto flotante, empleada aquí como referencia de compresión con pérdida controlada

Resumen

Título: Optimización de la gestión de memoria en simuladores cuánticos mediante la compresión de datos sin pérdida de precisión¹

Autores: Daniel Adrián González Buendía
Javier Andrés Sarmiento Salazar²

Palabras clave: Computación cuántica, Simulación cuántica, Gestión de memoria, Compresión de datos

Descripción:

La simulación clásica de circuitos cuánticos sigue siendo un recurso indispensable para diseñar, validar y analizar algoritmos cuánticos. No obstante, en los simuladores de estado completo su alcance práctico queda limitado por el crecimiento exponencial de la memoria requerida para almacenar el vector de estado. En respuesta a esta restricción, el presente trabajo estudia la compresión sin pérdida como mecanismo de gestión de memoria en simuladores cuánticos tipo Schrödinger, con el objetivo de reducir la huella de almacenamiento sin introducir alteraciones numéricas en la simulación.

La propuesta comprende la selección de un simulador base y de una biblioteca de compresión adecuada, el diseño de una arquitectura de almacenamiento por bloques con descompresión selectiva y caché LRU, su implementación en TMFQSfullstate mediante Blosc2 y su evaluación experimental frente a una ejecución de referencia sin compresión y a una estrategia con pérdida controlada basada en ZFP. La validación se realizó con circuitos representativos de comportamientos contrastantes de compresibilidad, en particular Grover y la transformada cuántica de Fourier, para instancias de 22, 23 y 24 qubits.

Los resultados muestran que la estrategia sin pérdida basada en Blosc logra reducciones significativas de memoria en escenarios favorables, especialmente en Grover, manteniendo coincidencia exacta con la referencia no comprimida y error absoluto máximo nulo en los casos

¹Trabajo de grado

²Facultad De Ingenierías Fisicomecánicas. Escuela De Ingeniería De Sistemas e Informática.
Director: PhD. Luis Alberto Núñez Martínez, Codirector: PhD. Gilberto Javier Díaz Toro

reportados. También evidencian que la eficacia de la compresión depende de la estructura del estado cuántico y del patrón de acceso al vector, por lo que no puede asumirse un beneficio uniforme entre algoritmos. En conjunto, el trabajo demuestra que la compresión sin pérdida es una alternativa viable para ampliar la capacidad práctica de simulación cuando la memoria es la restricción dominante y el estado conserva regularidades aprovechables.

Abstract

Title: Optimization of memory management in quantum simulators through data compression without loss of precision³

Authors: Daniel Adrián González Buendía
Javier Andrés Sarmiento Salazar⁴

Key words: Quantum Computing, Quantum Simulation, Memory Management, Data Compression

Description:

Classical quantum-circuit simulation remains an essential resource for designing, validating, and analyzing quantum algorithms. In full-state simulators, however, practical scale is limited by the exponential memory required to store the state vector. In response to that restriction, this thesis studies lossless compression as a memory-management mechanism for Schrödinger-style quantum simulators, aiming to reduce storage demands without introducing numerical alterations into the simulation.

The proposed approach includes the selection of a base simulator and a suitable compression library, the design of a block-based storage architecture with selective decompression and LRU caching, its implementation in TMFQSfullstate using Blosc2, and its experimental evaluation against both an uncompressed reference and a controlled-loss strategy based on ZFP. Validation was conducted with representative circuits exhibiting contrasting compressibility behavior, namely Grover’s algorithm and the quantum Fourier transform, for 22, 23, and 24 qubits.

The results show that the Blosc-based lossless strategy achieves significant memory reductions in favorable scenarios, especially for Grover, while preserving exact agreement with the uncompressed reference and zero maximum absolute error in the reported cases. They also show that compression effectiveness depends on the structure of the quantum state and

³Degree Thesis

⁴Faculty of Physics-Mechanics Engineering. School of Systems Engineering and Computer Science.
Advisor: PhD. Luis Alberto Núñez Martínez, Co-Advisor: PhD. Gilberto Javier Díaz Toro

on state-vector access patterns, so benefits cannot be assumed to be uniform across algorithms. Overall, the thesis demonstrates that lossless compression is a viable alternative for extending practical simulation capacity when memory is the dominant constraint and the state preserves exploitable regularity.

Introducción

La computación cuántica se ha consolidado como un campo con capacidad para abordar ciertos problemas mediante modelos de cómputo distintos a los de la computación clásica (Nielsen y Chuang, 2010). Sin embargo, el diseño, la depuración y la evaluación de algoritmos cuánticos siguen dependiendo en gran medida de la simulación clásica, que permite trabajar en entornos controlados, reproducibles y comparables antes de llevar los circuitos a hardware real (Jones, Brown, Bush, y Benjamin, 2019; Díaz, Steffenel, Barrios, y Couturier, 2024).

Dentro de ese panorama, la simulación de estado completo o tipo Schrödinger ocupa un lugar central por su generalidad: mantiene explícitamente el vector de amplitudes complejas y lo actualiza compuerta por compuerta durante la ejecución del circuito (Jones y cols., 2019; Qiskit Development Team, 2025). Esta representación ofrece una referencia detallada y exacta del sistema, pero también impone su principal límite práctico: para n qubits se requieren 2^n amplitudes, de modo que el costo de memoria crece exponencialmente. En doble precisión, ese crecimiento vuelve rápidamente inviable la simulación en hardware convencional; por ejemplo, 40 qubits demandan del orden de 16 TB y, al acercarse a 50 qubits, la exigencia entra en el rango de los petabytes (Wu y cols., 2019; Häner y Steiger, 2017).

La literatura ha respondido a esta restricción mediante estrategias como redes tensoriales, diagramas de decisión, particionamiento del circuito y compresión con pérdida controlada (Vidal, 2003; Viamontes, Markov, y Hayes, 2003; Chen, Zhang, Huang, Newman, y Shi, 2018; Wu y cols., 2018). Aunque estas alternativas han ampliado el rango de circuitos simulables, no resuelven el mismo problema bajo las mismas condiciones: unas sacrifican generalidad, otras trasladan el costo hacia el tiempo de cómputo y otras aceptan perturbaciones numéricas que resultan inconvenientes cuando se necesita una referencia exacta del estado.

En este contexto, la compresión sin pérdida de precisión resulta atractiva porque actúa sobre la forma de almacenar el vector de estado sin modificar sus amplitudes. Además, los arreglos científicos de punto flotante pueden contener regularidades aprovechables mediante

transformaciones reversibles y compresión por bloques, aun cuando no parezcan compresibles a simple vista (Burtscher y Ratanaworabhan, 2009; Lindstrom y Isenburg, 2006; Masui y cols., 2015).

Con base en esta idea, el presente trabajo estudia una estrategia de gestión de memoria para simuladores cuánticos de estado completo implementada sobre TMFQSfullstate (Gilberto Díaz, Jorge Saul, Daniel González Buendía, y Javier Sarmiento, 2026). La propuesta combina almacenamiento comprimido por bloques, descompresión selectiva y reutilización temporal mediante caché, y se evalúa frente a una referencia no comprimida y a una estrategia con pérdida basada en ZFP. El propósito no es únicamente reducir memoria, sino determinar en qué condiciones la compresión sin pérdida ofrece una relación favorable entre ahorro de espacio, sobrecarga temporal y exactitud numérica.

1 Planteamiento del problema

En un simulador cuántico tipo Schrödinger, cada incremento en el número de qubits duplica el tamaño del vector de estado. Como consecuencia, el consumo de memoria crece exponencialmente y se convierte en la restricción dominante mucho antes de que otras variables de desempeño se vuelvan críticas (Jones y cols., 2019; Wu y cols., 2019). El problema no es marginal: limita de forma directa el tamaño de los circuitos que pueden ejecutarse con exactitud en infraestructura clásica de uso académico o de laboratorio.

Las estrategias disponibles para aliviar esta restricción no son equivalentes entre sí. Los métodos basados en redes tensoriales, diagramas de decisión o particionamiento del circuito pueden ser muy efectivos, pero dependen de supuestos estructurales sobre el circuito o redistribuyen el costo hacia el tiempo de cómputo y la complejidad de la simulación (Viamontes y cols., 2003; Chen y cols., 2018). Por su parte, la compresión con pérdida ofrece ahorros importantes de memoria, aunque a costa de alterar las amplitudes y de reemplazar la igualdad exacta por métricas de aproximación o fidelidad (Wu y cols., 2018; Díaz Toro, 2025).

Esto deja abierto un problema específico: cómo reducir la huella de memoria del vector de estado sin cambiar el modelo de simulación ni introducir error numérico. Resolverlo exige algo más que añadir un compresor al almacenamiento. La utilidad real de la compresión depende de la estructura de los estados generados, de la granularidad con que se particiona el vector y del patrón de lecturas y escrituras inducido por las compuertas. En otras palabras, una estrategia viable debe integrar compresión, acceso selectivo y reutilización temporal de datos de manera coherente con la dinámica del simulador.

Bajo estas condiciones, el problema central de investigación se formula así: *¿cómo optimizar la gestión de memoria en simuladores cuánticos tipo Schrödinger mediante compresión de datos sin pérdida, de forma que se obtenga un ahorro significativo de memoria con una sobrecarga temporal razonable y se preserve igualdad exacta respecto a una ejecución no comprimida?*

Responder esta pregunta es relevante porque permitiría ampliar la escala práctica de la simulación exacta sin abandonar la representación de estado completo, que sigue siendo una referencia valiosa para validación, comparación y análisis detallado de circuitos cuánticos. Con base en este problema se derivan los objetivos que orientan el desarrollo del trabajo.

2 Objetivos

2.1 Objetivo general

- Diseñar e implementar una estrategia eficiente de gestión de memoria en simuladores cuánticos basada en técnicas de compresión sin pérdida de precisión, con el fin de optimizar el uso de recursos computacionales sin comprometer la exactitud numérica de las simulaciones.

2.2 Objetivos específicos

- Analizar el impacto del uso de herramientas de compresión de datos sin pérdida de precisión en el consumo de memoria, el tiempo de ejecución y la verificación de igualdad

exacta de los resultados respecto a una referencia no comprimida.

- Diseñar una estrategia integral de gestión de memoria basada en compresión sin pérdida de precisión, definiendo el algoritmo, los parámetros de compresión-descompresión y los puntos de integración con el simulador cuántico seleccionado.
- Desarrollar e integrar la estrategia diseñada en el simulador elegido, optimizando la sobrecarga computacional para garantizar un ahorro significativo de memoria sin afectar la exactitud numérica de la simulación.
- Implementar dos algoritmos cuánticos distintos en el simulador cuántico elegido para evaluar el uso de memoria, velocidad y exactitud con y sin compresión de datos.
- Comparar los resultados obtenidos con estrategias tradicionales y métodos que emplean compresión con pérdida de precisión, identificando ventajas y desventajas de cada enfoque.

3 Marco teórico

3.1 Fundamentos de información cuántica

3.1.1 *Qubits, espacio de estados y superposición*

La unidad básica de información en computación cuántica es el qubit. A diferencia del bit clásico, cuyo valor solo puede ser 0 o 1, un qubit se describe mediante un vector de estado en un espacio de Hilbert generado por los estados base $|0\rangle$ y $|1\rangle$ (Nielsen y Chuang, 2010). Un estado general puede escribirse como

$$|\psi\rangle = \alpha |0\rangle + \beta |1\rangle ,$$

donde α y β son amplitudes complejas que satisfacen la condición de normalización

$$|\alpha|^2 + |\beta|^2 = 1.$$

Esta expresión muestra que el estado cuántico no queda determinado por un valor discreto, sino por una combinación lineal de estados base. Esta propiedad se conoce como superposición y constituye una de las características fundamentales de la información cuántica (Nielsen y Chuang, 2010). En términos observables, al medir el sistema se obtiene uno de los estados base con probabilidades dadas por los módulos cuadrados de las amplitudes.

La formulación anterior puede generalizarse a registros de varios qubits. En ese caso, el espacio de estados total se obtiene mediante el producto tensorial de los espacios individuales, de modo que un sistema de n qubits se describe en un espacio vectorial de dimensión 2^n (Nielsen y Chuang, 2010). Su estado general se expresa como

$$|\psi\rangle = \sum_{i=0}^{2^n-1} \alpha_i |i\rangle,$$

donde $|i\rangle$ representa cada estado base de la base computacional y $\alpha_i \in \mathbb{C}$. Por ejemplo, para dos qubits:

$$|\psi\rangle = \alpha_{00} |00\rangle + \alpha_{01} |01\rangle + \alpha_{10} |10\rangle + \alpha_{11} |11\rangle.$$

La superposición adquiere aquí una forma más amplia: el sistema completo puede describirse como una combinación lineal de todos los estados base disponibles. Así, a medida que aumenta el número de qubits, crece también el número de amplitudes necesarias para describir el sistema con exactitud. Esta estructura matemática define el modo en que la información cuántica se representa antes de cualquier implementación computacional.

3.1.2 Entrelazamiento

El entrelazamiento aparece cuando el estado conjunto de un sistema no puede expresarse como el producto tensorial de estados independientes para cada una de sus partes (Nielsen y Chuang, 2010). En estos casos, la información del sistema deja de poder describirse completamente a partir de sus componentes por separado y pasa a estar contenida en el estado global.

Un ejemplo clásico es el estado de Bell

$$|\Phi^+\rangle = \frac{1}{\sqrt{2}} (|00\rangle + |11\rangle).$$

Este estado no puede factorizarse como $|\psi_1\rangle \otimes |\psi_2\rangle$, por lo que sus componentes no admiten una descripción independiente completa. El entrelazamiento introduce correlaciones no clásicas entre las partes del sistema y constituye uno de los rasgos distintivos de la computación cuántica (Nielsen y Chuang, 2010).

Desde una perspectiva operativa, esta propiedad resulta fundamental porque muchas transformaciones cuánticas generan, modifican o explotan correlaciones de este tipo. En consecuencia, el entrelazamiento no solo es una característica teórica del modelo, sino también una propiedad estructural de gran importancia en la evolución de los estados cuánticos.

3.1.3 Interferencia

La interferencia es la propiedad mediante la cual las amplitudes complejas de un estado cuántico pueden combinarse de forma constructiva o destructiva durante la evolución del sistema (Nielsen y Chuang, 2010). A diferencia de un esquema puramente probabilístico, en un sistema cuántico no se suman directamente probabilidades, sino amplitudes, y solo después se obtienen probabilidades a partir de sus módulos cuadrados.

Esto implica que la fase relativa entre amplitudes desempeña un papel central. Dos contribuciones de magnitud similar pueden reforzarse entre sí o cancelarse parcialmente según

su relación de fase. Por esta razón, la evolución cuántica no depende únicamente de cuánto “peso” tenga cada estado base, sino también de cómo se relacionan sus amplitudes complejas.

La interferencia explica cómo ciertas configuraciones del sistema pueden aumentar su probabilidad de observación mientras otras disminuyen, aun cuando todas formen parte de la misma superposición. Junto con la superposición y el entrelazamiento, esta propiedad define la dinámica fundamental con la que la información cuántica es transformada.

3.2 Modelo de circuitos cuánticos

3.2.1 Evolución unitaria y compuertas cuánticas

El modelo de circuitos cuánticos representa un algoritmo como una secuencia finita de transformaciones unitarias aplicadas sobre un registro de qubits (Nielsen y Chuang, 2010). Si el estado actual del sistema es $|\psi\rangle$ y se aplica una operación unitaria U , el nuevo estado queda dado por

$$|\psi'\rangle = U |\psi\rangle.$$

Las compuertas cuánticas son, por tanto, operadores unitarios que transforman el estado preservando su norma. Entre las compuertas de un qubit más utilizadas se encuentran las compuertas de Pauli, la compuerta Hadamard y distintas compuertas de fase.

La compuerta Hadamard se expresa como

$$H = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

y actúa sobre los estados base de la siguiente manera:

$$H |0\rangle = \frac{|0\rangle + |1\rangle}{\sqrt{2}}, \quad H |1\rangle = \frac{|0\rangle - |1\rangle}{\sqrt{2}}.$$

Esta compuerta es especialmente relevante porque transforma estados base en superpo-

siciones y constituye un bloque elemental en múltiples circuitos.

En términos generales, si un circuito aplica sucesivamente las compuertas $U_1, U_2, \dots, U_k$, el estado final puede escribirse como

$$|\psi_f\rangle = U_k \cdots U_2 U_1 |\psi_0\rangle.$$

Esta descripción resalta que el circuito puede interpretarse como una composición ordenada de transformaciones lineales sobre el vector de estado.

3.2.2 Compuertas controladas y operaciones sobre varios qubits

Además de las operaciones de un solo qubit, los circuitos cuánticos utilizan compuertas que actúan sobre más de un qubit de manera conjunta. Una de las más conocidas es la compuerta CNOT, que aplica una negación controlada sobre un qubit objetivo dependiendo del valor del qubit de control (Nielsen y Chuang, 2010).

Las compuertas controladas permiten construir correlaciones entre qubits y son fundamentales para la generación de entrelazamiento. Por ejemplo, si se parte de $|00\rangle$, se aplica una compuerta Hadamard al primer qubit y después una CNOT controlada por ese mismo qubit, el resultado es

$$\frac{|00\rangle + |11\rangle}{\sqrt{2}},$$

que corresponde a un estado entrelazado.

En el modelo de circuitos, estas compuertas amplían la capacidad expresiva del sistema al introducir dependencias entre subsistemas. Su efecto puede describirse algebraicamente mediante matrices unitarias de mayor dimensión, aunque en la práctica suelen implementarse mediante reglas de actualización local sobre el vector de estado.

3.2.3 Medición

La medición conecta el sistema cuántico con los resultados observables (Nielsen y Chuang, 2010). Si el estado del sistema es

$$|\psi\rangle = \sum_{i=0}^{2^n-1} \alpha_i |i\rangle,$$

la probabilidad de observar el estado base $|i\rangle$ está dada por

$$P(i) = |\alpha_i|^2.$$

Tras la medición, el sistema deja de describirse como una superposición general y pasa a corresponder a un resultado concreto compatible con la observación realizada. Por esta razón, en la mayoría de los circuitos la medición se reserva para el final o para etapas puntuales del proceso.

Desde una perspectiva de simulación, esto significa que el objeto central durante la ejecución no es todavía la salida observada, sino el conjunto completo de amplitudes que describe al sistema antes de medir.

3.3 Del modelo cuántico a su representación clásica

3.3.1 El vector de estado como representación computacional

La forma más directa de representar un sistema cuántico en una computadora clásica consiste en almacenar explícitamente su vector de estado. En este enfoque, el sistema de n qubits se materializa como una secuencia de 2^n amplitudes complejas:

$$|\psi\rangle = \sum_{i=0}^{2^n-1} \alpha_i |i\rangle \longrightarrow [\alpha_0, \alpha_1, \alpha_2, \dots, \alpha_{2^n-1}].$$

Cada elemento del arreglo representa una amplitud del sistema, mientras que su posición identifica el estado base asociado. Esta equivalencia convierte la formulación matemática

del estado cuántico en una estructura de datos concreta sobre la cual pueden aplicarse operaciones numéricas.

El uso explícito del vector de estado caracteriza a la simulación de estado completo, también conocida como simulación tipo Schrödinger (Jones y cols., 2019). En ella, el sistema se representa manteniendo todas sus amplitudes y actualizándolas conforme se aplican las compuertas del circuito. La principal ventaja de esta aproximación es su correspondencia directa con la formulación matemática del modelo cuántico.

Existen otros enfoques de simulación clásica, como los basados en redes tensoriales, diagramas de decisión o métodos de suma sobre caminos (Vidal, 2003; Viamontes y cols., 2003; Chen y cols., 2018). De manera general, estos métodos buscan representar la evolución cuántica mediante estructuras alternativas que explotan diferentes formas de organización algebraica o combinatoria. Sin embargo, la representación explícita por vector de estado ofrece el marco más directo para comprender cómo se traduce un sistema cuántico a memoria clásica y cómo se implementa su evolución sobre arreglos numéricos. Esta distinción también es importante porque no todas las estrategias para reducir memoria cambian la representación matemática del estado: algunas, como la que se estudia en este trabajo, mantienen el formalismo Schrödinger y actúan únicamente sobre la manera de almacenar los datos.

3.3.2 Organización del vector de estado en memoria

En una implementación clásica, cada amplitud α_i es un número complejo que puede expresarse como

$$\alpha_i = a_i + b_i \text{i},$$

donde a_i es la parte real y b_i la parte imaginaria. Si se utiliza doble precisión, ambas partes suelen almacenarse como valores de 8 bytes, por lo que cada amplitud compleja ocupa 16 bytes (Jones y cols., 2019; Wu y cols., 2019).

Conceptualmente, el estado puede verse como un arreglo de números complejos

$$[\alpha_0, \alpha_1, \alpha_2, \dots, \alpha_{2^n-1}]$$

o, de forma más explícita, como una secuencia numérica intercalada

$$[\text{real}_0, \text{imag}_0, \text{real}_1, \text{imag}_1, \dots, \text{real}_{2^n-1}, \text{imag}_{2^n-1}].$$

Esta segunda forma resulta útil para visualizar cómo un objeto abstracto de la mecánica cuántica termina almacenado como datos numéricos lineales en memoria principal.

La correspondencia entre índice, estado base y representación numérica puede ilustrarse con un sistema de tres qubits:

Índice	Estado base	Amplitud asociada	Representación numérica
0	$ 000\rangle$	α_0	$\text{Re}(\alpha_0), \text{Im}(\alpha_0)$
1	$ 001\rangle$	α_1	$\text{Re}(\alpha_1), \text{Im}(\alpha_1)$
2	$ 010\rangle$	α_2	$\text{Re}(\alpha_2), \text{Im}(\alpha_2)$
3	$ 011\rangle$	α_3	$\text{Re}(\alpha_3), \text{Im}(\alpha_3)$
4	$ 100\rangle$	α_4	$\text{Re}(\alpha_4), \text{Im}(\alpha_4)$
5	$ 101\rangle$	α_5	$\text{Re}(\alpha_5), \text{Im}(\alpha_5)$
6	$ 110\rangle$	α_6	$\text{Re}(\alpha_6), \text{Im}(\alpha_6)$
7	$ 111\rangle$	α_7	$\text{Re}(\alpha_7), \text{Im}(\alpha_7)$

Tabla 1: Correspondencia entre estado base, amplitud e índice en memoria para un sistema de 3 qubits.

Usualmente, esta correspondencia sigue el orden binario natural del índice entero i , lo que permite enlazar directamente la base computacional con la disposición lineal del arreglo.

3.3.3 Aplicación de compuertas sobre el arreglo de amplitudes

Una vez que el estado cuántico se representa como un arreglo lineal, la aplicación de compuertas puede entenderse como una secuencia de operaciones numéricas sobre subconjuntos

específicos de amplitudes.

En una compuerta de un solo qubit, la transformación no afecta una amplitud aislada, sino pares de amplitudes cuyos índices difieren en el bit asociado al qubit objetivo. En un sistema de tres qubits puede tomarse la convención $(q_2q_1q_0)$, donde q_2 es el bit más significativo y q_0 el menos significativo. Con esta convención, la Tabla 2 muestra cómo cambian los pares afectados según la posición del qubit objetivo.

Objetivo q_0 (se mantienen fijos q_2 y q_1)		
Bits fijos (q_2q_1)	Estados relacionados	Par afectado
00	$000 \leftrightarrow 001$	(α_0, α_1)
01	$010 \leftrightarrow 011$	(α_2, α_3)
10	$100 \leftrightarrow 101$	(α_4, α_5)
11	$110 \leftrightarrow 111$	(α_6, α_7)
Objetivo q_2 (se mantienen fijos q_1 y q_0)		
Bits fijos (q_1q_0)	Estados relacionados	Par afectado
00	$000 \leftrightarrow 100$	(α_0, α_4)
01	$001 \leftrightarrow 101$	(α_1, α_5)
10	$010 \leftrightarrow 110$	(α_2, α_6)
11	$011 \leftrightarrow 111$	(α_3, α_7)

Tabla 2: Pares de amplitudes afectados por una compuerta de un solo qubit en un sistema de 3 qubits, mostrando qué bits permanecen fijos y cuál varía según el qubit objetivo.

Esto muestra que el patrón de actualización depende de la posición del qubit sobre el cual se aplica la compuerta. De forma análoga, una compuerta de dos qubits modifica grupos más grandes de amplitudes, pero siempre siguiendo una regla determinada por la estructura binaria de los índices.

Desde el punto de vista computacional, esta regularidad introduce patrones de acceso sobre el arreglo. Algunas operaciones actúan sobre posiciones contiguas y otras sobre posiciones separadas por saltos regulares, de modo que la simulación no solo depende del tamaño total del vector, sino también de cómo se distribuyen las lecturas y escrituras en memoria. En este contexto, las nociones de localidad espacial y localidad temporal ayudan a entender por

qué ciertas estrategias de particionamiento, acceso selectivo y reutilización temporal pueden resultar convenientes.

Esta interpretación computacional del circuito es importante porque establece el vínculo entre álgebra lineal y acceso a memoria: simular la evolución cuántica equivale, en este marco, a recorrer, leer, combinar y reescribir posiciones concretas de un arreglo de amplitudes complejas.

3.3.4 Consideraciones básicas de almacenamiento y acceso

Si cada amplitud compleja ocupa 16 bytes, el consumo de memoria del vector de estado puede expresarse como

$$M(n) = 2^n \times 16 \text{ bytes.}$$

Esta relación resume el costo directo de almacenar explícitamente el sistema en una simulación de estado completo (Jones y cols., 2019; Wu y cols., 2019). Más allá del tamaño total, también importa el modo en que las compuertas inducen patrones de acceso sobre el arreglo: algunas operaciones actúan sobre elementos contiguos, mientras que otras requieren recorrer posiciones separadas por saltos regulares.

Por tanto, la representación clásica del vector de estado involucra dos aspectos complementarios: cuánto espacio se necesita para almacenar las amplitudes y cómo se accede a ellas durante la evolución del circuito. Estos dos elementos son fundamentales para entender la gestión de memoria sobre arreglos numéricos de gran tamaño.

3.4 Gestión de memoria y compresión de datos en arreglos numéricos

3.4.1 Gestión de memoria en simulación científica

La gestión de memoria en computación científica comprende las técnicas utilizadas para organizar, almacenar, recuperar y reutilizar estructuras numéricas de gran tamaño durante la ejecución de un programa. En este tipo de aplicaciones, el rendimiento no depende única-

mente del costo aritmético de las operaciones, sino también del comportamiento de los datos en memoria.

Cuando una estructura domina el volumen de almacenamiento y concentra buena parte de los accesos, su organización interna se vuelve especialmente importante. En estos casos, aspectos como la granularidad del acceso, la reutilización temporal y la disposición lineal o segmentada de los datos pueden influir de manera significativa en el comportamiento global del sistema.

Desde esta perspectiva, una estructura como el vector de estado puede analizarse no solo como objeto matemático, sino también como carga principal de memoria dentro de una simulación numérica.

3.4.2 Conceptos generales de compresión de datos

La compresión de datos es el proceso mediante el cual una secuencia de información se representa utilizando menos espacio que en su forma original. La posibilidad de comprimir depende de la existencia de redundancia o regularidad aprovechable en los datos.

En términos generales, los métodos de compresión se clasifican en sin pérdida y con pérdida. La compresión sin pérdida permite recuperar exactamente los datos originales después de descomprimir. La compresión con pérdida, en cambio, admite una reconstrucción aproximada a cambio de mayores reducciones de tamaño.

En datos numéricos, la compresibilidad puede venir de repeticiones, regiones homogéneas, distribuciones estructuradas o relaciones locales entre valores cercanos. Sin embargo, los arreglos en punto flotante presentan una estructura binaria que suele ser menos intuitiva que la de datos textuales o discretos, por lo que su compresión requiere técnicas adecuadas a esa naturaleza.

3.4.3 *Compresión sin pérdida en datos de punto flotante*

La compresión sin pérdida de arreglos de punto flotante busca reducir el espacio de almacenamiento preservando exactamente cada valor original. Esto implica que, tras la descompresión, tanto la representación numérica como la secuencia binaria asociada a cada dato deben coincidir con las del arreglo inicial.

Aunque los datos en punto flotante pueden parecer poco compresibles a simple vista, en muchos contextos científicos presentan regularidades explotables. Estas regularidades no siempre se manifiestan como repeticiones exactas de valores, sino también como similitudes locales en exponentes, mantisas o agrupaciones de datos con cierta estructura. Compresores como FPC y FPZIP fueron diseñados precisamente para explotar este tipo de regularidades en arreglos de punto flotante sin alterar sus valores (Burtscher y Ratanaworabhan, 2009; Lindstrom y Isenburg, 2006).

Por ello, la compresibilidad de un arreglo numérico depende tanto del contenido como de la forma en que este se organiza antes de aplicar el compresor. Esta observación es importante cuando se trabaja con arreglos densos de amplitudes complejas, cuya estructura puede variar según el estado representado.

3.4.4 *Compresión por bloques, descompresión selectiva y caché*

Una estrategia habitual para manejar arreglos grandes consiste en particionarlos en bloques y comprimir cada bloque de manera independiente. Esta organización permite trabajar de forma más granular sobre los datos y evita la necesidad de comprimir o descomprimir la estructura completa ante cada operación. En propuestas recientes de simulación cuántica con compresión, este tipo de organización se combina con mecanismos de acceso parcial y administración jerárquica de memoria para reducir presión sobre la RAM o la memoria del acelerador (Wu y cols., 2019; Zhang y cols., 2024).

La descompresión selectiva se basa en esa granularidad: solo se reconstruyen temporalmente los bloques necesarios para una operación determinada. De este modo, la compresión

puede integrarse con el patrón de acceso del sistema y no únicamente con el almacenamiento final de los datos.

La granularidad del bloque introduce, sin embargo, un compromiso importante. Bloques grandes suelen capturar mejor la redundancia disponible y favorecer mejores tasas de compresión, pero incrementan el costo cuando solo una pequeña fracción de los datos es necesaria. Bloques pequeños permiten accesos más localizados, aunque pueden degradar el rendimiento del compresor y aumentar el peso relativo del metadato y de la administración.

Cuando ciertos bloques son reutilizados con frecuencia en intervalos cortos, resulta útil mantenerlos temporalmente en una caché. Una política frecuente para administrar esta caché es LRU (*Least Recently Used*), que reemplaza primero los bloques menos recientemente utilizados. Esta política se apoya en la localidad temporal y busca reducir el costo de descompresiones repetidas.

Bloques, descompresión selectiva y caché conforman así un conjunto de conceptos que permiten pensar la compresión como parte activa de la gestión de memoria sobre arreglos numéricos de gran tamaño.

3.4.5 *Exactitud numérica e igualdad exacta*

En aplicaciones científicas, no siempre basta con obtener resultados aproximados. En muchos casos se requiere preservar exactamente los valores almacenados, de modo que cualquier transformación aplicada a los datos sea completamente reversible.

La compresión sin pérdida satisface este requisito mediante la propiedad de igualdad exacta, según la cual los datos recuperados después de descomprimir coinciden completamente con los originales. Este criterio es más fuerte que otras métricas numéricas basadas en error absoluto, error relativo o fidelidad, ya que no admite desviaciones, por pequeñas que sean. Expresado sobre un vector de amplitudes, este requisito puede escribirse como

$$\alpha_i^{(\text{orig})} = \alpha_i^{(\text{rec})} \quad \forall i.$$

En arreglos de amplitudes complejas, esta propiedad significa que tanto la parte real como la parte imaginaria de cada elemento deben recuperarse sin alteración. Como medida auxiliar de discrepancia, puede emplearse el error absoluto máximo

$$e_{\text{abs}} = \max_i \left| \alpha_i^{(\text{orig})} - \alpha_i^{(\text{rec})} \right|,$$

el cual debe ser nulo en una estrategia estrictamente sin pérdida. Desde un punto de vista metodológico, ello permite distinguir claramente entre optimización del almacenamiento y modificación del contenido numérico.

4 Estado del arte

4.1 Simuladores cuánticos

La simulación clásica de circuitos cuánticos es esencial para el desarrollo y validación de algoritmos cuánticos. Sin embargo, el principal desafío radica en la representación del estado cuántico, cuyo tamaño crece exponencialmente con el número de qubits.

Uno de los primeros enfoques para abordar este problema fue la representación mediante *Matrix Product States* (MPS), propuesta por Vidal (2003). Este método permite representar ciertos estados cuánticos de forma eficiente cuando el entrelazamiento es limitado, reduciendo los requisitos de almacenamiento y cómputo. Su principal ventaja es la escalabilidad en circuitos con baja profundidad, permitiendo simular cientos de qubits. No obstante, su limitación radica en que para sistemas altamente entrelazados el costo computacional crece exponencialmente, restringiendo su aplicabilidad a ciertos algoritmos.

A medida que se buscaban métodos más generales, surgió la simulación tipo *Schrödinger*, que almacena el vector de estado completo y lo actualiza en cada operación cuántica. Este enfoque, empleado en simuladores como QuEST y Qiskit Aer (Jones y cols., 2019; Qiskit Development Team, 2025), garantiza alta precisión y permite simular cualquier circuito cuántico. Su desventaja principal es la extrema demanda de memoria, la cual crece exponen-

cialmente con el número de qubits: una simulación de 45 qubits ya ha requerido 0.5 petabytes de memoria (Häner y Steiger, 2017), y al extender esta representación de doble precisión a 50 qubits el costo pasa al orden de decenas de petabytes.

Para mitigar el problema de memoria, se desarrollaron métodos basados en partición del circuito y caminos de Feynman. Por ejemplo, Chen y cols. presentaron un algoritmo distribuido capaz de calcular amplitudes de salida y simular circuitos universales de hasta 12×12 qubits con profundidad moderada sin materializar el estado completo (Chen y cols., 2018). Sin embargo, aunque reducen el almacenamiento requerido, estos métodos incrementan la complejidad computacional, ya que el número de caminos crece exponencialmente con la profundidad del circuito.

4.2 Compresión de memoria con pérdida de precisión

Dado que la representación exacta de estados cuánticos es ineficiente en términos de memoria, se han explorado técnicas de compresión con pérdida de precisión. Estos enfoques sacrifican una pequeña cantidad de fidelidad numérica a cambio de una reducción significativa en el uso de memoria, permitiendo la simulación de circuitos más grandes.

Uno de los primeros enfoques en este ámbito fue el de Wu y cols. (2018, 2019), quienes introdujeron la compresión adaptativa con error acotado. Utilizando la biblioteca SZ, lograron reducir el tamaño del vector de estado hasta en un factor de 16, manteniendo fidelidades superiores al 99.9%. Su principal ventaja es que permite ampliar el número de qubits simulados sin un incremento proporcional en los requisitos de memoria. Sin embargo, la compresión y descompresión recurrente introduce sobrecarga computacional, afectando la eficiencia temporal de la simulación.

En un esfuerzo por maximizar la escala de la simulación cuántica de estado completo, Zhang y cols. (2024) presentaron *BMQSim*, un marco que extiende *SV-Sim* mediante el uso de **compresores con pérdida de precisión y control de error punto a punto** ejecutados directamente en GPU (por ejemplo, variantes de la familia SZ/cuSZ)(Zhang y

cols., 2024). Su diseño combina:

- Una estrategia de *circuit partitioning* que disminuye la frecuencia de (des)compresión.
- Un *pipeline* solapado que oculta en gran medida el coste de mover y comprimir datos.
- Una gestión de memoria jerárquica (VRAM + SSD mediante GPUDirect Storage) que asigna dinámicamente espacio a los bloques comprimidos.

Con estas técnicas, BMQSim reduce el consumo de memoria en más de un orden de magnitud y mantiene fidelidades superiores al 99 % sin penalizar de forma apreciable el tiempo de simulación. Su eficacia, sin embargo, está condicionada a la disponibilidad de hardware acelerado con GPUs de alto rendimiento y unidades NVMe rápidas, lo que puede restringir su adopción en plataformas de menor capacidad computacional.

Más recientemente, Huffman, Pavlichin, y Weissman (2024) exploraron la cuantización de amplitudes como un mecanismo para reducir la precisión numérica sin afectar la fidelidad global del sistema. Demostraron que representaciones con tan solo 7 bits por amplitud permiten mantener una fidelidad superior al 99 %, lo que sugiere que la precisión completa de punto flotante puede ser innecesaria en muchas simulaciones. Aunque esta técnica ofrece un enfoque simple y eficiente para reducir el uso de memoria, su aplicabilidad a circuitos de gran escala aún requiere validación empírica.

Díaz Toro (2025) propone un esquema de **vector de estado comprimido** que emplea compresores con pérdida de precisión, principalmente *ZFP* en modo *fixed-rate*, complementado por *SZ*, para reducir la huella de memoria del simulador. El autor reporta reducciones del **10–20 %** en casos base y, en configuraciones de mayor escala, ahorros que alcanzan hasta un **75 %** de la memoria requerida. *ZFP* opera sobre bloques independientes de 4^d valores, de modo que la (des)compresión de cada bloque se realiza en completo aislamiento del resto; esto permite solapar dichas operaciones con el cómputo principal y amortiguar la sobrecarga introducida. Aunque la compresión incrementa el tiempo de ejecución, el impacto se compensa al transmitir los fragmentos del vector en formato comprimido dentro de una arquitectura

distribuida basada en *MPI*, reduciendo el volumen de comunicación y habilitando simulaciones de hasta 30 qubits en los experimentos reportados. Finalmente, el estudio concluye que esta estrategia de *estado completo comprimido distribuido* resulta más fiable y escalable que la *poda de estados de baja probabilidad*, la cual presenta descensos de fidelidad y sobrecarga adicional que la hacen desaconsejable.

4.3 Compresión de memoria sin pérdida de precisión

La simulación cuántica eficiente requiere reducir el consumo de memoria sin comprometer la fidelidad del estado cuántico. Para ello, se han desarrollado técnicas de compresión sin pérdida de precisión que buscan representar estados y operadores cuánticos de manera más compacta sin alterar sus valores.

Uno de los primeros enfoques en esta dirección fue el uso de diagramas de decisión cuánticos (*Quantum Information Decision Diagrams*, QuIDD), introducidos por Viamontes y cols. (2003). Este método permite representar vectores de estado y operadores unitarios aprovechando redundancias estructurales en sus coeficientes, lo que permite una representación más eficiente en memoria. Su ventaja radica en que, para circuitos con alta redundancia, el crecimiento en memoria puede reducirse de exponencial a polinomial. Sin embargo, su eficacia se limita a circuitos con estructura repetitiva, fallando en casos de entrelazamiento complejo.

En un desarrollo posterior, Miller y Thornton (2006) propusieron los *Quantum Multiple-valued Decision Diagrams* (QMDD), los cuales extienden la representación de QuIDD mediante el uso de aristas ponderadas con matrices unitarias. Esto permitió manejar de manera más eficiente circuitos reversibles y operadores cuánticos de mayor tamaño. Aunque estos diagramas optimizan la representación de puertas lógicas y matrices densas, su eficiencia sigue dependiendo de la estructura interna del circuito.

Más recientemente, Jaques y Häner (2021) exploraron la esparsidad del estado cuántico para almacenar solo las amplitudes no nulas, reduciendo significativamente el almacena-

miento requerido en algoritmos con exploración limitada del espacio de Hilbert. Su enfoque demostró ser altamente eficiente en problemas de factorización y aritmética cuántica, pero pierde efectividad en circuitos con alta interferencia y entrelazamiento.

En 2023, Vinkhuijzen, Coopmans, Elkouss, Dunjko, y Laarman (2023) introdujeron los *Local Invertible Map Decision Diagrams* (LIMDD), una evolución de los diagramas de decisión que incorpora transformaciones locales para mejorar la representación compacta del estado cuántico. Esta técnica permite manejar estados estabilizadores y ciertas estructuras altamente entrelazadas que eran difíciles de representar con diagramas de decisión tradicionales. No obstante, su aplicabilidad sigue limitada a casos donde las transformaciones locales puedan ser explotadas para reducir la complejidad estructural.

Estos avances en compresión sin pérdida han permitido extender la capacidad de simulación de circuitos cuánticos en hardware clásico. Sin embargo, aún existen limitaciones en la representación de estados arbitrarios, lo que ha llevado a la exploración de otros métodos para optimizar el uso de memoria.

4.4 Enfoques de compresión sin pérdida para datos de punto flotante

En simulación científica es frecuente trabajar con arreglos extensos de números de punto flotante, cuyo volumen puede convertir el almacenamiento y el movimiento de datos en una restricción de desempeño. En este contexto, la compresión sin pérdida busca reducir el tamaño de la representación binaria sin alterar ningún bit de la información original, de modo que la reconstrucción coincida exactamente con los datos de entrada. Esta exigencia es especialmente relevante en escenarios donde los valores comprimidos participan posteriormente en nuevas etapas de cálculo o sirven como referencia numérica exacta.

A diferencia de la compresión de texto o de datos discretos, la compresión de punto flotante presenta dificultades particulares. Muchos arreglos científicos contienen redundancias asociadas a continuidad espacial, dependencia temporal o regularidades en la representación binaria de signo, exponente y mantisa. Sin embargo, cuando esas regularidades son débiles

o no siguen una estructura local simple, la compresión se vuelve más desafiante. Por esta razón, la literatura ha propuesto distintos enfoques que no actúan todos del mismo modo: algunos se basan en predicción, otros en transformaciones reversibles de la representación binaria y otros en reorganización tipada de los datos antes de aplicar un códec general.

4.4.1 *FPC (Burtscher & Ratanaworabhan)*

FPC (Floating Point Compressor) (Burtscher y Ratanaworabhan, 2009) es un algoritmo de compresión sin pérdida diseñado para secuencias lineales de valores de punto flotante, especialmente en doble precisión. Su principio central consiste en predecir el siguiente valor a partir del historial reciente y comprimir únicamente la diferencia entre el valor real y el valor estimado.

Para ello, FPC emplea dos predictores derivados de esquemas tipo FCM/DFCM, cuyos resultados se comparan con el dato real mediante una operación XOR. Cuando la predicción es cercana, la diferencia resultante presenta una cantidad considerable de bytes iniciales nulos, que pueden codificarse de forma compacta. El algoritmo almacena entonces un pequeño código de control junto con los bytes residuales no nulos. De esta manera, la compresión depende directamente de la capacidad del predictor para anticipar la estructura local de la secuencia.

Este enfoque resulta especialmente adecuado cuando existe correlación entre valores adyacentes o cuando la evolución del arreglo mantiene cierta regularidad. En cambio, su efectividad disminuye cuando los datos no exhiben continuidad local suficiente para que la predicción produzca residuos pequeños. Aun así, FPC constituye una referencia importante en compresión sin pérdida de punto flotante porque muestra con claridad la utilidad y las limitaciones de los esquemas predictivos sobre representaciones IEEE 754.

4.4.2 *FPZIP (Lindstrom & Isenburg)*

FPZIP (Lindstrom y Isenburg, 2006) es un compresor sin pérdida orientado a arreglos de punto flotante en contextos científicos. Su diseño parte de la idea de que muchos conjuntos de datos numéricos presentan continuidad o dependencia local, de modo que pueden describirse con mayor eficiencia a partir de errores de predicción que a partir de los valores originales.

A diferencia de enfoques lineales simples, *FPZIP* incorpora esquemas de predicción adaptados a la estructura de los datos, lo que le permite aplicarse a arreglos de distintas dimensionalidades. Tras generar una estimación para cada valor, el algoritmo codifica el residuo de predicción mediante un modelo entrópico diseñado para preservar exactitud bit a bit sobre la representación en punto flotante. En este sentido, *FPZIP* no requiere cuantización ni aproximación intermedia: la compresión sigue siendo estrictamente reversible.

La relevancia de *FPZIP* radica en que explota de manera más general la estructura local de arreglos científicos y combina predicción con codificación entrópica especializada. Esto lo convierte en un referente importante para datos en los que la redundancia no se manifiesta únicamente entre valores consecutivos, sino también en relaciones espaciales o estructurales más amplias.

4.4.3 *Bitshuffle con LZ4 (Masui et al.)*

Una estrategia diferente consiste en no predecir los valores, sino transformar su disposición binaria para hacer visibles regularidades que no son evidentes en el orden original. Bajo esta idea, *Bitshuffle* (Masui y cols., 2015) actúa como un filtro reversible que reorganiza los bits de una secuencia de valores de punto flotante antes de aplicar un códec de compresión general, usualmente LZ4.

El procedimiento puede entenderse como una transposición bit a bit: si se consideran N valores de m bits, sus representaciones binarias forman una matriz de $N \times m$, y *Bitshuffle* reordena los datos agrupando los bits según su posición. Esta transformación puede revelar repeticiones o patrones en determinados planos de bits, por ejemplo en exponentes o signos,

que de otra forma quedarían dispersos entre los bytes de cada valor. Una vez realizada la transposición, un códec LZ puede aprovechar con mayor eficacia esas secuencias más homogéneas.

Este enfoque no depende de predicciones locales entre valores adyacentes, sino de la posibilidad de exponer regularidades internas de la representación binaria. Por ello, su interés en compresión científica es doble: por un lado, preserva completamente la exactitud; por otro, ofrece una vía distinta para explotar redundancia en datos donde los modelos predictivos no siempre resultan adecuados. En la práctica, Bitshuffle suele entenderse mejor como una transformación previa al códec que como un compresor autosuficiente.

4.4.4 *Transformación de Datos Tipados (TDT)*

La *Transformación de Datos Tipados* (TDT)(Jamalidinan y Cheshmi, 2025) representa una línea más reciente de trabajo orientada a reorganizar datos de punto flotante antes de aplicar compresión generalista. A diferencia de Bitshuffle, que opera sobre una transposición fija de bits, TDT busca identificar posiciones de byte con comportamientos estadísticos diferentes y reagruparlas para producir flujos más homogéneos.

La idea central es que, en una representación IEEE 754, no todos los bytes cumplen el mismo papel ni presentan el mismo nivel de entropía. Los bytes asociados al exponente, al signo o a distintas regiones de la mantisa pueden exhibir distribuciones distintas según la naturaleza de los datos. TDT analiza esas diferencias a nivel de bloque y aplica una reorganización reversible basada en características estadísticas, de modo que los bytes con comportamiento semejante queden contiguos antes de ser entregados a un compresor convencional.

Más que un códec independiente, TDT debe entenderse como un preprocesamiento tipado orientado a mejorar la eficiencia de compresores generales sobre datos numéricos. Su relevancia dentro del estado del arte radica en mostrar que la compresión sin pérdida de flotantes no depende únicamente de predicción o de compresión entrópica, sino también de la capacidad de reordenar la representación binaria para hacer más visible su estructura

estadística.

4.5 Otros métodos de optimización de memoria

Además de la compresión sin pérdida, se han desarrollado enfoques alternativos para reducir el consumo de memoria en simuladores cuánticos, incluyendo técnicas basadas en redes tensoriales, poda de estados y optimización HPC.

Uno de los primeros enfoques en esta dirección fue propuesto por Markov y Shi (2008), quienes introdujeron el uso de redes tensoriales para simular circuitos cuánticos mediante contracción optimizada de tensores. En este método, el circuito se representa como un grafo tensorial, y su simulación se optimiza contrayendo secuencias de tensores en un orden eficiente. Esto permite representar ciertos circuitos con memoria subexponencial, aunque la efectividad del método depende de la estructura del entrelazamiento.

Posteriormente, Boixo, Isakov, Smelyanskiy, y Neven (2017) propusieron un modelo gráfico para circuitos cuánticos de baja profundidad basado en la eliminación de variables en grafos probabilísticos. Su técnica permitió simular circuitos aleatorios cercanos al régimen de supremacía cuántica en hardware clásico, extendiendo el tamaño de circuitos simulables sin necesidad de almacenar el estado cuántico completo. Sin embargo, este método pierde eficacia conforme aumenta la profundidad del circuito.


En paralelo, Pednault y cols. (2017) introdujeron técnicas de diferimiento de contracciones tensoriales en simulaciones HPC. Su propuesta permite manejar circuitos más grandes al intercambiar memoria por cómputo adicional, almacenando resultados intermedios en memoria secundaria y evitando la expansión total del estado cuántico en RAM. Esta estrategia ha sido clave en la simulación de circuitos con estructuras altamente no triviales, aunque su implementación requiere acceso a infraestructuras de supercomputación.

Finalmente, como se analizó previamente, la tesis doctoral de Díaz Toro (2025) introduce técnicas de compresión con pérdida de precisión en esquemas distribuidos de simulación cuántica. Este antecedente resulta especialmente relevante porque consolida el uso de bi-

bibliotecas científicas de compresión, vectores de estado y paralelismo distribuido con *MPI* como una línea válida para reducir consumo de memoria en simulación cuántica. Al mismo tiempo, deja visible un espacio de estudio complementario: evaluar hasta qué punto técnicas de compresión **sin pérdida de precisión** pueden aportar reducciones útiles de memoria sin introducir discrepancias numéricas en el estado simulado.

5 Metodología de la investigación

El presente trabajo se desarrolló mediante una metodología de investigación aplicada con evaluación experimental. Dado que el problema abordado exigía intervenir un simulador cuántico real, incorporar una estrategia de compresión sin pérdida de precisión y verificar su efecto sobre memoria, tiempo y exactitud numérica, la metodología se estructuró como un proceso de diseño, implementación y validación comparativa. En consecuencia, el trabajo combinó revisión del estado del arte, selección justificada de herramientas, diseño de una arquitectura de almacenamiento, desarrollo de la solución e instrumentación experimental sobre cargas de trabajo representativas.

Figura 1: Metodología de investigación

5.1 Diseño

La fase de diseño estableció la base conceptual y técnica de la propuesta. En esta etapa se realizó la revisión del estado del arte sobre simulación cuántica de estado completo, compresión de datos de punto flotante y estrategias de optimización de memoria, con énfasis en enfoques sin pérdida de precisión aplicables al vector de estado. Esta revisión permitió identificar las alternativas existentes, sus limitaciones y su pertinencia frente al problema específico de reducir la huella de memoria sin alterar el resultado numérico de la simulación.

A partir de este análisis se definieron los criterios para la selección del simulador cuántico base. Se consideraron aspectos como la apertura y modificabilidad del código fuente, la facilidad de intervención sobre la representación del vector de estado, la compatibilidad con optimizaciones de memoria, el soporte de paralelismo y la posibilidad de instrumentar métricas experimentales. La selección se formalizó mediante una matriz de evaluación ponderada entre las alternativas consideradas.

Finalmente, se definió la arquitectura general de la solución. En esta etapa se establecieron la organización del vector de estado en bloques, los mecanismos de compresión y descompresión selectiva, la estrategia de reutilización temporal de datos y los puntos de integración con el simulador seleccionado. Con ello se delimitó el marco de implementación de la propuesta y se fijaron los supuestos que orientarían su evaluación posterior.

5.2 Implementación e integración de la estrategia

La segunda fase correspondió al desarrollo de la estrategia diseñada y su integración en el simulador seleccionado. El objetivo fue materializar la arquitectura propuesta en una implementación funcional capaz de operar sobre el almacenamiento del vector de estado sin modificar el modelo general de simulación.

Para ello se intervino el código fuente del simulador en los componentes asociados a la representación, acceso y actualización del vector de amplitudes, incorporando el esquema de almacenamiento comprimido sin pérdida. Esta integración incluyó la gestión de bloques comprimidos, los procedimientos de recuperación y actualización de datos, y los mecanismos requeridos para su persistencia durante la ejecución del circuito.

De forma complementaria, se optimizó el esquema de acceso al almacenamiento con el fin de controlar la sobrecarga asociada a la compresión y descompresión. Estas adaptaciones buscaron favorecer la reutilización temporal de bloques y reducir accesos innecesarios, de modo que el ahorro de memoria no implicara un deterioro desproporcionado del tiempo de ejecución.

Una vez integrada la estrategia, se realizaron pruebas iniciales sobre circuitos de validación para comprobar la estabilidad del desarrollo y verificar, en el caso de la propuesta sin pérdida, la coincidencia exacta del estado final frente a la referencia no comprimida.

5.3 Evaluación experimental

La evaluación experimental se diseñó para determinar el efecto de la estrategia de compresión sobre el comportamiento del simulador en términos de uso de memoria, costo temporal y exactitud numérica. En particular, esta fase buscó establecer en qué condiciones la compresión sin pérdida constituye una alternativa viable frente al almacenamiento no comprimido y cómo se compara con una estrategia complementaria de compresión con pérdida controlada.

La campaña experimental se planteó sobre cargas de trabajo con comportamientos de compresibilidad contrastantes. Para ello se seleccionaron dos familias de circuitos: la Transformada Cuántica de Fourier (QFT) y el algoritmo de búsqueda de Grover. Esta selección permitió evaluar la propuesta en escenarios con estructuras de estado y patrones de acceso diferentes, evitando que la valoración dependiera de un único tipo de circuito.

La comparación se realizó entre tres escenarios: una ejecución de referencia sin compresión, una ejecución con la estrategia de compresión sin pérdida integrada en el simulador y una ejecución con una estrategia de compresión con pérdida controlada. Bajo esta organización fue posible analizar tanto el ahorro de memoria como la sobrecarga temporal y el comportamiento de la exactitud numérica en cada enfoque.

Las métricas principales de evaluación fueron el tiempo total de ejecución y el uso máximo de memoria durante la simulación. Adicionalmente, la exactitud se evaluó de forma diferenciada según la naturaleza de la estrategia comparada. En la propuesta sin pérdida, el criterio de validación consistió en verificar igualdad exacta entre el estado final comprimido y la referencia no comprimida:

$$\alpha_i^{(\text{ref})} = \alpha_i^{(\text{comp})} \quad \forall i.$$

En la estrategia con pérdida controlada, la discrepancia respecto a la referencia se resumió mediante el error absoluto máximo:

$$e_{\text{abs}} = \max_i \left| \alpha_i^{(\text{ref})} - \alpha_i^{(\text{comp})} \right|.$$

Con el fin de reducir la dependencia de configuraciones particulares, en Grover se consideraron múltiples instancias por tamaño, mientras que en QFT se evaluó una instancia por familia de entrada y por número de qubits. Finalmente, la exactitud se verificó mediante la exportación y comparación completa del vector de amplitudes frente a la referencia no comprimida. En la estrategia sin pérdida, esta comparación permitió confirmar igualdad exacta amplitud por amplitud; en la estrategia con pérdida, el mismo procedimiento se empleó para calcular el máximo error absoluto. De este modo, la evaluación experimental quedó orientada a establecer los compromisos entre memoria, tiempo y exactitud en las estrategias de almacenamiento consideradas.

6 Selección del simulador cuántico base

6.1 Necesidad de seleccionar un simulador base

La propuesta de este trabajo no se limita a ejecutar circuitos cuánticos sobre una herramienta existente, sino que exige intervenir la representación del vector de estado para integrar una estrategia de compresión sin pérdida de precisión y evaluar su efecto sobre memoria, tiempo y exactitud numérica. Por esta razón, la selección del simulador base constituye una decisión metodológica central, ya que condiciona la viabilidad de la integración, el alcance de la instrumentación experimental y el esfuerzo técnico requerido para desarrollar la solución.

En los simuladores cuánticos tipo Schrödinger, el vector de estado es la estructura principal del cálculo y, a la vez, la fuente dominante del consumo de memoria. En consecuencia, el simulador seleccionado debía permitir una intervención suficientemente directa sobre esa representación, sin desplazar el problema hacia restricciones derivadas de abstracciones internas difíciles de modificar o de mecanismos poco accesibles para observación experimental.

Con este propósito se consideraron cinco alternativas representativas dentro del ecosis-

tema de simulación cuántica de estado completo: QuEST, Intel-QS, qsim, Quantum++ y TMFQSfullstate. La elección se formalizó mediante criterios explícitos y una matriz de evaluación ponderada, de modo que la decisión quedara vinculada a los objetivos técnicos y experimentales del trabajo.

6.2 Criterios de selección

Los criterios de selección se definieron a partir de los requerimientos del problema y de las necesidades metodológicas de la propuesta. En particular, se priorizaron aquellos aspectos relacionados con la posibilidad de intervenir el almacenamiento del vector de estado, instrumentar el comportamiento del simulador y mantener condiciones reproducibles de evaluación.

Tabla 3: Criterios usados para la selección del simulador cuántico

	Criterio	Justificación	Peso
C1	Correspondencia con el modelo de simulación objetivo	Se valora que la herramienta implemente simulación de estado completo tipo Schrödinger y exponga una representación compatible con amplitudes complejas en punto flotante, de forma que la compresión se aplique sobre la estructura realmente dominante en memoria.	0.15
C2	Grado de intervención sobre la representación del estado	Se evalúa en qué medida el código permite reemplazar, envolver o modificar el almacenamiento del vector de amplitudes con impacto controlado sobre el resto del simulador. Este criterio es central, porque la propuesta requiere intervenir la estructura principal de datos y no únicamente usar el simulador como entorno de ejecución.	0.25
C3	Capacidad de instrumentación experimental	Se considera la facilidad para medir tiempo de ejecución, memoria y comportamiento de rutas críticas próximas al acceso al vector de estado. Un simulador adecuado debe permitir una evaluación trazable y reproducible del efecto de la compresión.	0.20
C4	Suficiencia funcional para los casos de prueba	Se verifica que la herramienta permita implementar y ejecutar los circuitos empleados en la evaluación, en particular Grover y QFT, con el conjunto de compuertas y operaciones necesarias para reproducir los escenarios experimentales definidos.	0.10
C5	Reproducibilidad técnica del entorno	Se valora la complejidad de construcción, el número de dependencias y la facilidad de compilar y mantener una versión modificada del simulador durante el desarrollo experimental. Este criterio no mide desempeño, sino riesgo técnico de integración.	0.10
C6	Contexto de paralelismo y escalamiento	Se considera deseable que la herramienta disponga de mecanismos de paralelismo relevantes, como ejecución multihilo o distribuida, ya que ello permite situar la propuesta en un contexto realista de simulación de alto costo computacional.	0.10
C7	Afinidad con experimentación en memoria	Se valora si la herramienta, por su arquitectura o propósito, favorece el estudio de estrategias de gestión de memoria, incluyendo variantes de almacenamiento, particionamiento del estado o experimentación sobre consumo de recursos.	0.10

Los pesos asignados reflejan el objetivo del trabajo. Por esta razón, los criterios con

mayor incidencia fueron el grado de intervención sobre la representación del estado (C2), la capacidad de instrumentación experimental (C3) y la correspondencia con el modelo de simulación objetivo (C1). Los demás criterios complementan la evaluación al considerar cobertura funcional, reproducibilidad técnica, paralelismo y afinidad con el problema de memoria abordado.

6.3 Simuladores considerados

Las alternativas evaluadas corresponden a herramientas pertinentes para simulación cuántica de estado completo, aunque con énfasis distintos en cuanto a rendimiento, portabilidad, facilidad de uso o experimentación.

- **QuEST (Quantum Exact Simulation Toolkit):** simulador de alto rendimiento orientado a vectores de estado y matrices de densidad, con soporte para ejecución multihilo, distribuida y acelerada por GPU. Su diseño privilegia escalabilidad y desempeño en arquitecturas heterogéneas. (Jones y cols., 2019; QuEST-Kit contributors, s.f.)
- **Intel-QS (Intel Quantum Simulator):** simulador de circuitos cuánticos basado en representación completa del estado, concebido para aprovechar arquitecturas multinúcleo y multinodo. Su enfoque está orientado a entornos HPC y a la eficiencia en ejecución paralela. (Intel-QS project, s.f.)
- **qsim:** biblioteca de simulación de estado completo integrada al ecosistema de Cirq, optimizada para calcular el estado final de circuitos cuánticos. Su orientación principal está asociada a la ejecución eficiente de circuitos y a su uso como backend de simulación. (quantumlib contributors, s.f.; Google Quantum AI, s.f.)
- **Quantum++:** biblioteca general en C++ para simulación cuántica, distribuida como librería *header-only* y diseñada con énfasis en portabilidad, facilidad de uso y soporte multihilo. Su arquitectura la hace adecuada para prototipado y experimentación ligera. (Gheorghiu, 2018)

- **TMFQSfullstate:** prototipo de simulador desarrollado en C++ con foco en estudiar estrategias de representación y consumo de memoria sobre simulación de estado completo. Su diseño favorece la intervención directa sobre la representación del estado y la exploración de variantes relacionadas con gestión de memoria y paralelismo. (Díaz y cols., 2024; Díaz, Steffemel, Barrios, y Couturier, 2025; Gilberto Díaz y cols., 2026)

En conjunto, las alternativas cubren dos perfiles. Por un lado, QuEST, Intel-QS y qsim representan herramientas consolidadas con fuerte orientación a rendimiento y ejecución eficiente. Por otro, Quantum++ y TMFQSfullstate ofrecen entornos más favorables para intervención directa sobre el código y experimentación sobre la representación del estado. Esta distinción es relevante porque la selección debía responder al problema específico de integración y evaluación planteado en esta tesis.

6.4 Matriz de evaluación ponderada

Con base en los criterios anteriores, se aplicó una matriz de decisión ponderada en una escala discreta de 1 a 5, donde 5 representa el mayor grado de adecuación al objetivo del trabajo y 1 el menor. Los puntajes corresponden a una valoración relativa respecto a la posibilidad de integrar, instrumentar y evaluar una estrategia de compresión sin pérdida sobre el vector de estado.

Tabla 4: Evaluación de alternativas (escala 1–5) y total ponderado

Criterio	Peso	TMFQS	QuEST	Intel-QS	qsim	Quantum++
C1	0.15	5	5	5	5	4
C2	0.25	5	3	2	2	3
C3	0.20	5	3	2	2	3
C4	0.10	3	5	5	5	4
C5	0.10	4	3	2	2	5
C6	0.10	4	5	5	4	3
C7	0.10	5	3	3	2	2
Total	1.00	4.70	3.70	3.20	2.90	3.30

La matriz muestra que las alternativas mejor orientadas a rendimiento y paralelismo no coinciden necesariamente con las mejor posicionadas para intervenir e instrumentar el almacenamiento del estado. En este marco, **TMFQSfullstate** obtiene la mayor puntuación global, principalmente por su ventaja en los criterios de intervención sobre la representación del estado, capacidad de instrumentación experimental y afinidad con el estudio de estrategias de memoria.

6.5 Selección del simulador

A partir de la matriz de la tabla 4, se selecciona **TMFQSfullstate** como simulador base para este trabajo.

La elección se sustenta en que ofrece el entorno más adecuado para integrar la estrategia propuesta, observar su efecto sobre el almacenamiento del vector de estado y mantener control experimental sobre la evaluación. Su arquitectura favorece la intervención directa sobre la representación interna del estado, reduce el riesgo técnico de integración y resulta coherente con el problema central de esta tesis, orientado a la optimización de memoria en simuladores cuánticos tipo Schrödinger mediante compresión sin pérdida de precisión.

7 Selección de la biblioteca de compresión sin pérdida

7.1 Necesidad de seleccionar una biblioteca de compresión

Una vez definido el simulador base, la siguiente decisión metodológica consiste en seleccionar la biblioteca de compresión sin pérdida que permita materializar la arquitectura propuesta sobre el vector de estado. En este trabajo, la compresión no se plantea como una operación aislada de almacenamiento, sino como parte de un esquema de gestión de memoria basado en particionamiento por bloques, descompresión selectiva y reutilización temporal de datos. Por ello, la biblioteca elegida debía ser compatible con un patrón de acceso repetido de lectura, modificación y escritura sobre fragmentos del estado, y no únicamente ofrecer una buena tasa de compresión en escenarios secuenciales u orientados a archivo.

Bajo estas condiciones, la selección no debía responder solo al ratio de compresión reportado por una biblioteca, sino a su adecuación como componente de una ruta crítica de simulación numérica. En particular, interesaban bibliotecas utilizables desde C/C++, con operación completamente sin pérdida, soporte eficiente para datos residentes en memoria y una integración razonable en un esquema de bloques independientes.

7.2 Criterios de selección

Los criterios de selección se definieron a partir del problema específico de esta tesis: comprimir sin pérdida el vector de estado de un simulador tipo Schrödinger sin romper la igualdad exacta respecto a la referencia ni introducir una sobrecarga desproporcionada en las operaciones de acceso. Por esta razón, se priorizaron criterios relacionados con integración, acceso por bloques, costo temporal de recuperación y adecuación a datos numéricos homogéneos.

Como condiciones mínimas de inclusión se establecieron las siguientes: operación sin pérdida, disponibilidad de interfaz utilizable desde C/C++, licenciamiento compatible con uso académico y posibilidad de comprimir datos residentes en memoria. Las bibliotecas

comparadas satisfacen estas condiciones.

Tabla 5: Criterios para la selección de bibliotecas de compresión sin pérdida

	Criterio	Justificación	Peso
C1	Adecuación a compresión por bloques en memoria	Se evalúa si la biblioteca favorece un esquema de datos particionado en bloques independientes, compatible con compresión y descompresión local sin necesidad de reconstruir el arreglo completo en cada operación. Este criterio es central porque la arquitectura propuesta descansa precisamente en ese patrón de acceso.	0.25
C2	Latencia de descompresión y acceso	Se valora el costo de recuperar datos comprimidos cuando solo una fracción del vector de estado debe pasar temporalmente a representación densa. En un simulador, la descompresión forma parte de la ruta crítica, por lo que la latencia de acceso tiene un peso metodológico mayor que el ratio aislado.	0.20
C3	Facilidad de integración e instrumentación en C/C++	Se considera la claridad de la API, el control sobre buffers y parámetros operativos, y la facilidad de incorporar la biblioteca al simulador manteniendo trazabilidad experimental. Este criterio mide riesgo técnico de integración.	0.20
C4	Adecuación a arreglos numéricos homogéneos	Se valora si la biblioteca dispone de mecanismos especialmente útiles para datos científicos en punto flotante, como filtros reversibles o preconditionadores que ayuden a exponer regularidades binarias sin alterar los valores.	0.15
C5	Flexibilidad de configuración	Se considera la posibilidad de ajustar niveles, filtros, códecs o modos de operación para explorar compromisos entre ahorro de memoria y costo temporal sin reestructurar la arquitectura del simulador.	0.10
C6	Madurez y estabilidad del ecosistema	Se valora la disponibilidad de documentación, mantenimiento, estabilidad de la biblioteca y adopción suficiente para reducir incertidumbre durante el desarrollo experimental.	0.10

Los pesos asignados priorizan la naturaleza del problema. La mayor importancia recae en la adecuación a compresión por bloques en memoria (C1), la latencia de descompresión (C2) y la facilidad de integración e instrumentación en C/C++ (C3), porque esos son los

aspectos que más influyen en la viabilidad de insertar compresión sin pérdida dentro de la dinámica del simulador. Los demás criterios complementan la decisión al considerar afinidad con datos científicos, flexibilidad operativa y estabilidad del ecosistema.

7.3 Bibliotecas de compresión sin pérdida consideradas

Las alternativas evaluadas corresponden a bibliotecas o familias de bibliotecas utilizables desde C/C++ y relevantes para compresión sin pérdida de datos residentes en memoria. No todas fueron diseñadas específicamente para simulación científica, pero todas representan opciones plausibles para integrarse en una arquitectura de almacenamiento comprimido.

- **Blosc2:** biblioteca orientada a compresión de datos binarios y arreglos numéricos, concebida alrededor de contenedores por bloques y de un pipeline de filtros y códecs configurable. Su diseño incorpora filtros como *shuffle* y *bitshuffle*, y permite combinar distintos códecs dentro de un marco pensado para datos estructurados y acceso en memoria. (Blosc Development Team, s.f.)
- **Zstandard (Zstd):** biblioteca generalista de compresión sin pérdida con amplio rango de compromiso entre velocidad y ratio. Ofrece funciones de compresión y descompresión en memoria y resulta adecuada como códec base cuando la aplicación controla externamente el particionamiento de los datos. (facebook/zstd contributors, s.f.; Zstandard project, s.f.)
- **LZ4:** biblioteca de compresión sin pérdida orientada a muy baja latencia, especialmente fuerte en descompresión. Su perfil la hace atractiva cuando el costo temporal del acceso pesa más que la tasa de compresión. (lz4 contributors, s.f.)
- **zlib/Deflate:** solución madura y ampliamente adoptada para compresión sin pérdida en memoria y en flujo. Aunque no está especializada en arreglos científicos ni en acceso por bloques, constituye una referencia estable para contrastar bibliotecas más recientes. (zlib authors, 2022)

Las cuatro alternativas cubren perfiles diferentes. Blosc2 representa una biblioteca con orientación explícita a datos numéricos y estructuras particionadas; Zstd y LZ4 son bibliotecas generalistas de alto desempeño que pueden funcionar como códecs dentro de una arquitectura definida por la aplicación; y zlib aporta una referencia clásica, madura y bien conocida. Esta selección permite comparar una opción especialmente alineada con el problema de memoria del trabajo frente a alternativas generalistas de compresión sin pérdida.

7.4 Matriz de evaluación ponderada

Con base en los criterios anteriores, se aplicó una matriz de evaluación ponderada en una escala discreta de 1 a 5, donde 5 representa el mayor grado de adecuación al objetivo del trabajo y 1 el menor. Los puntajes no deben interpretarse como una medida absoluta de calidad de cada biblioteca, sino como una valoración relativa respecto a su conveniencia para integrarse en una arquitectura de almacenamiento comprimido por bloques dentro del simulador seleccionado.

Tabla 6: Evaluación de bibliotecas de compresión sin pérdida (escala 1–5) y total ponderado

Criterio	Peso	Blosc2	Zstd	LZ4	zlib
C1	0.25	5	3	3	2
C2	0.20	4	4	5	2
C3	0.20	5	4	4	4
C4	0.15	5	2	2	2
C5	0.10	5	4	3	2
C6	0.10	4	5	5	5
Total	1.00	4.75	3.55	3.45	2.70

La matriz muestra una diferencia clara entre bibliotecas generalistas de compresión y una biblioteca diseñada con mayor afinidad hacia datos numéricos particionados. Zstd y LZ4 obtienen una valoración favorable en velocidad y madurez, pero dependen en mayor

medida de que la arquitectura de bloques sea resuelta externamente por la aplicación. `zlib` conserva valor como referencia estable, aunque resulta menos atractivo para una ruta crítica sensible a latencia y acceso parcial. En cambio, `Blosc2` concentra ventajas en los criterios más relevantes para esta tesis: compresión por bloques en memoria, facilidad de integración y adecuación a arreglos numéricos homogéneos (Blosc Development Team, s.f.).

7.5 Selección de la biblioteca de compresión

A partir de la matriz de la tabla 6, se selecciona **Blosc2** como biblioteca de compresión sin pérdida para este trabajo.

La elección se sustenta en que `Blosc2` ofrece el entorno más adecuado para materializar la arquitectura propuesta de almacenamiento comprimido por bloques. Su diseño está alineado con datos binarios y numéricos en memoria, incorpora filtros reversibles útiles para arreglos de punto flotante y permite combinar la compresión con una organización natural por fragmentos, lo que reduce el esfuerzo de implementación respecto a una integración basada únicamente en códecs generales (Blosc Development Team, s.f.).

Además, `Blosc2` permite mantener flexibilidad experimental sin cambiar de biblioteca: dentro de su marco pueden explorarse distintos filtros, configuraciones y códecs, lo que resulta especialmente valioso en una investigación cuyo interés no es solo comprimir, sino estudiar el compromiso entre ahorro de memoria, sobrecarga temporal y exactitud numérica bajo una arquitectura controlada. En consecuencia, `Blosc2` se adopta como la opción más consistente con los objetivos técnicos y metodológicos de esta tesis.

8 Patrones de compresibilidad en vectores de estado de algoritmos cuánticos

8.1 Relación entre estructura del estado y compresibilidad

La simulación cuántica de estado completo representa el sistema mediante un vector de amplitudes complejas cuyo tamaño crece como 2^n (siendo n el número de qubits). En este contexto, la *compresibilidad* del vector depende fuertemente de los patrones numéricos que

generan los algoritmos: simetrías, valores repetidos, regiones con ceros exactos o distribuciones altamente estructuradas tienden a favorecer la compresión; por el contrario, estados densos con amplitudes variadas y poco redundantes tienden a reducir la efectividad de compresores sin pérdida.

En las subsecciones siguientes se describen patrones típicos de varios algoritmos conocidos y su impacto esperado en compresión de vectores de estado. Esta discusión cumple una función interpretativa y de selección de casos de prueba: no constituye por sí misma la validación experimental del trabajo. La contrastación empírica posterior se concentra en Grover y QFT, que representan dos regímenes estructurales suficientemente distintos para evaluar la estrategia propuesta.

8.2 Búsqueda de Grover: uniformidad y baja entropía

Grover inicia preparando una superposición uniforme sobre $N = 2^n$ estados base, usualmente aplicando compuertas de Hadamard a cada qubit. En esa preparación ideal, todas las amplitudes tienen el mismo valor (magnitud constante), por lo que el vector de estado queda compuesto por un único valor repetido N veces, un caso altamente favorable para compresión sin pérdida (Grover, 1996; Szabłowski, 2021).

Tras cada iteración (oráculo + difusión), la estructura permanece altamente regular: cuando existe un único elemento marcado, el vector puede describirse con dos categorías principales de amplitud (una asociada al estado marcado y otra común al resto de estados no marcados). Esta simetría reduce el número de valores distintos en el vector, lo cual incrementa la redundancia explotable por compresión.

La misma simetría admite una reducción más fuerte cuando el objetivo es simular únicamente la evolución ideal de Grover con un conjunto fijo de estados marcados. Si W denota el conjunto de estados objetivo y $M = |W|$, el estado puede expresarse en el subespacio generado por

$$|w\rangle = \frac{1}{\sqrt{M}} \sum_{x \in W} |x\rangle, \quad |r\rangle = \frac{1}{\sqrt{N-M}} \sum_{x \notin W} |x\rangle,$$

de modo que en cada iteración basta actualizar dos parámetros globales en lugar de las N amplitudes individuales. Esta observación no sustituye una estrategia general de almacenamiento, pero sí muestra que la estructura algorítmica de Grover permite optimizaciones adicionales cuando se preserva la igualdad de amplitud dentro de las clases marcada y no marcada. La derivación correspondiente se presenta en el Apéndice A.

De manera empírica, se ha reportado que la compresión permite escalar simulaciones de Grover significativamente más allá de lo que permitiría almacenar el vector sin comprimir. Por ejemplo, Wu y cols. muestran una reducción drástica del requerimiento de memoria para una simulación de Grover de 61 qubits al combinar técnicas de compresión con ejecución en supercomputación (Wu y cols., 2019).

8.3 Transformada cuántica de Fourier: variación de fase y baja redundancia

La Transformada Cuántica de Fourier (QFT) aplicada a un estado base $|k\rangle$ produce una superposición con magnitudes uniformes pero fases dependientes del índice. En su forma ideal, la amplitud de cada componente $|x\rangle$ puede expresarse como:

$$a_x = \frac{1}{\sqrt{N}} e^{\frac{2\pi i k x}{N}},$$

lo cual implica que, aunque la magnitud sea constante, las partes real e imaginaria varían de forma oscilatoria con x .

Desde la perspectiva de almacenamiento, este comportamiento tiende a generar arreglos *densos* donde la mayoría de entradas son no nulas y muchas de ellas difieren entre sí. En consecuencia, la redundancia directa (por repetición exacta) suele ser baja para compresión estrictamente sin pérdida. En un estudio de integración de compresión en simulación cuántica se observa que, a medida que avanza un circuito QFT, el ratio de compresión puede caer desde valores altos en etapas iniciales hasta valores cercanos a 1 (poca o nula compresión efectiva) en etapas finales (Wu y cols., 2018). Este comportamiento ilustra que los estados

generados por QFT pueden ser un caso exigente para compresión sin pérdida, especialmente cuando el circuito densifica el vector de estado.

8.4 Algoritmo de Shor: periodicidad y concentración espectral

Shor combina (i) una etapa de exponenciación modular que induce periodicidad y (ii) una QFT que transforma esa periodicidad en una distribución con picos relacionados con el período. En términos cualitativos, antes de aplicar QFT suelen aparecer patrones donde solo ciertos índices compatibles con una estructura periódica presentan amplitud significativa; dependiendo de la instancia, esto puede producir regiones con ceros exactos o repeticiones regulares que favorecen la compresión.

Tras QFT, la distribución tiende a concentrarse alrededor de múltiplos específicos asociados a la frecuencia/período, generando picos dominantes y muchos valores de magnitud pequeña. En compresión estrictamente sin pérdida, la ganancia depende de si existen ceros exactos o repeticiones; cuando predominan muchos valores pequeños pero distintos, la redundancia disminuye. Estos escenarios se alinean con el fenómeno observado en circuitos que incrementan progresivamente la densidad del estado: conforme aparecen más amplitudes no nulas y variadas, el ratio de compresión disminuye (Wu y cols., 2018).

8.5 Deutsch–Jozsa y Simon: estructura y esparsidad

Varios algoritmos tempranos construyen superposiciones altamente estructuradas mediante oráculos e interferencia.

En Deutsch–Jozsa, la interferencia inducida por el oráculo y la transformación final de Hadamard concentra la amplitud sobre un subconjunto reducido de estados base cuando la función pertenece a una de las clases consideradas por el algoritmo. Este tipo de concentración implica esparsidad o repetición exacta de amplitudes, lo que favorece la compresión sin pérdida (Deutsch y Jozsa, 1992; Nielsen y Chuang, 2010).

En Simon, tras medir el registro de salida, el registro de entrada colapsa a una super-

posición de dos estados relacionados por una máscara secreta. Ese estado intermedio es extremadamente esparso y, por tanto, muy compresible. Posteriormente, la aplicación de compuertas de Hadamard produce una superposición uniforme sobre un subconjunto definido por una restricción lineal, donde reaparecen ceros exactos y amplitudes repetidas (Simon, 1997; Nielsen y Chuang, 2010).

8.6 Circuitos variacionales y circuitos aleatorios: entre regularidad y alta entropía

En aplicaciones NISQ, algunos circuitos variacionales producen distribuciones de amplitud sesgadas por la estructura del problema, lo cual puede inducir regularidades (por ejemplo, subconjuntos dominantes o restricciones que eliminan estados). Esto puede mejorar la compresibilidad frente a escenarios plenamente aleatorios.

Por el contrario, circuitos aleatorios profundos tienden a generar estados altamente entrelazados y con amplitudes densas, donde la diversidad de valores reduce la redundancia. En simulación con compresión, este fenómeno se manifiesta como una caída del ratio a medida que el circuito genera más amplitudes no nulas y variadas, tal como se evidencia en evaluaciones de compresión sobre circuitos que densifican el vector de estado (por ejemplo, QFT) (Wu y cols., 2018).

8.7 Implicaciones para la compresión sin pérdida

Los ejemplos anteriores sugieren una heurística práctica: algoritmos que preservan simetrías fuertes (valores repetidos), esparsidad (ceros exactos) o distribuciones con pocas categorías de amplitud tienden a ser más favorables para compresión sin pérdida. En cambio, transformaciones que producen estados densos y con amplitudes altamente variadas limitan la efectividad de compresores sin pérdida.

Esta relación patrón-compresibilidad es un insumo útil para diseñar experimentos y seleccionar casos de prueba representativos al evaluar técnicas de reducción de memoria en

simuladores cuánticos. Resultados experimentales sobre compresión en simulación de circuitos muestran precisamente que, en presencia de estados densos y sin reglas simples de distribución, el ratio puede acercarse a 1 (Wu y cols., 2018), mientras que en algoritmos con alta regularidad (como Grover) pueden observarse reducciones de memoria sustanciales (Wu y cols., 2019).

9 Diseño de la arquitectura de compresión sin pérdida para simuladores tipo Schrödinger


Una vez seleccionado el simulador base y definida la biblioteca de compresión, el siguiente paso consiste en establecer una arquitectura que permita reducir la huella de memoria del vector de estado sin alterar la semántica de la simulación ni comprometer la igualdad exacta de los resultados. Esta exigencia impone una restricción importante: la compresión no puede introducirse como una etapa externa de almacenamiento, sino como parte del mecanismo mediante el cual el simulador representa, accede y actualiza las amplitudes durante la ejecución del circuito.

El análisis del capítulo anterior mostró que la compresibilidad de un vector de estado no es uniforme, sino que depende de la estructura efectiva del estado generado por el algoritmo cuántico. Mientras algunos circuitos producen amplitudes con alta regularidad o redundancia, otros generan distribuciones densas y poco favorables para compresión. Por esta razón, la arquitectura propuesta no asume que todo el vector de estado deba permanecer descomprimido ni que toda operación justifique recomprimir el arreglo completo. En cambio, se adopta un diseño por bloques que busca desacoplar el ahorro de memoria del costo de acceso, permitiendo que la compresión actúe de forma local y bajo demanda.

Bajo esta lógica, la propuesta se organiza alrededor de cuatro decisiones arquitectónicas: particionar el vector de estado en bloques independientes, aplicar descompresión selectiva solo sobre los bloques requeridos por cada operación, mantener una caché temporal de bloques activos y estructurar la compresión como un flujo reversible sobre cada bloque. En conjunto,

estas decisiones definen un esquema de almacenamiento comprimido compatible con la dinámica de un simulador cuántico tipo Schrödinger y preparan la base para su implementación posterior.

Figura 2: Arquitectura por bloques para la integración de compresión sin pérdida en simuladores cuánticos tipo Schrödinger



9.1 Objetivos de diseño

El diseño de la arquitectura se orientó por tres objetivos principales. El primero fue preservar la exactitud numérica de la simulación, de modo que la representación comprimida no introdujera diferencias respecto a una ejecución de referencia no comprimida. El segundo consistió en reducir la memoria ocupada por el vector de estado sin exigir su reconstrucción completa ante cada operación. El tercero fue mantener una sobrecarga temporal razonable, de forma que el ahorro espacial no dependiera de una penalización prohibitiva en tiempo de ejecución.

Estos objetivos implican que la arquitectura debía cumplir dos condiciones simultáneamente. Por un lado, toda transformación aplicada al almacenamiento del estado debía ser estrictamente reversible. Por otro, el acceso al vector debía adaptarse al patrón local con que las compuertas actúan sobre las amplitudes, evitando tratamientos globales cuando la actualización solo involucra una fracción del arreglo.

Desde esta perspectiva, el diseño no busca sustituir el modelo de simulación de estado completo, sino modificar su representación física en memoria. El vector de amplitudes se mantiene como referencia lógica del simulador, pero su materialización pasa a depender de una capa intermedia capaz de alternar entre forma comprimida y forma densa según las necesidades de acceso de cada operación. Esta separación entre representación lógica y representación física es la base que articula el resto de la propuesta.


9.2 Representación por bloques del vector de estado

La primera decisión de diseño consiste en particionar el vector de estado en bloques contiguos e independientes. Cada bloque agrupa un subconjunto de amplitudes adyacentes en memoria y se considera la unidad básica de compresión, descompresión, persistencia y reemplazo dentro del sistema. Con esta organización, el vector deja de tratarse como un único arreglo monolítico y pasa a manejarse como una colección de fragmentos sobre los cuales puede actuarse de manera localizada.

Esta decisión responde a una motivación tanto espacial como operacional. Desde el punto de vista de memoria, la compresión por bloques permite que partes distintas del vector presenten ratios diferentes según su contenido efectivo. Desde el punto de vista del acceso, evita que una operación que afecta solo una región reducida del estado obligue a descomprimir o recomprimir el arreglo completo. La granularidad del bloque se convierte así en un parámetro central del diseño, ya que determina simultáneamente el potencial de compresión y el costo de recuperar datos para la simulación.

La representación por bloques también favorece una integración más limpia con el simulador. En lugar de alterar la semántica de las operaciones cuánticas, la arquitectura interpone una capa de almacenamiento que resuelve qué bloque contiene cada amplitud, cómo se recupera temporalmente y cuándo debe volver a forma comprimida. Esto conserva el modelo de ejecución del simulador, pero reemplaza la idea de un vector siempre residente en memoria densa por un backend capaz de administrar bloques en distintos estados de materialización.

Figura 3: Particionamiento abstracto del vector de estado en bloques independientes



9.3 Descompresión selectiva y estrategia de acceso

Una vez adoptada la representación por bloques, el principio operativo de la arquitectura es que solo deben descomprimirse los bloques necesarios para ejecutar una operación. La

descompresión selectiva constituye, por tanto, la segunda decisión de diseño y el mecanismo que vincula el ahorro de memoria con el patrón real de acceso del simulador.

En un simulador tipo Schrödinger, muchas compuertas actualizan amplitudes cuya relación puede resolverse localmente dentro de una región acotada del vector, mientras que otras inducen interacciones entre posiciones que pertenecen a bloques distintos. La arquitectura debe poder manejar ambos casos sin perder consistencia. Cuando todas las amplitudes requeridas por la operación se encuentran en un mismo bloque, el acceso es enteramente local: el bloque se materializa en memoria densa, se ejecuta la actualización y luego se decide si permanece temporalmente activo o si vuelve a almacenamiento comprimido. Cuando la operación involucra amplitudes distribuidas en bloques distintos, la arquitectura debe adquirir simultáneamente los bloques necesarios, aplicar la actualización y coordinar su posterior permanencia o escritura diferida.

Este enfoque permite que la compresión actúe de forma compatible con la lógica del simulador. El costo de acceso deja de depender del tamaño total del vector y pasa a depender del número de bloques activados por cada compuerta, de la localidad del patrón de acceso y de la frecuencia con la que esos mismos bloques vuelven a ser requeridos. En consecuencia, la efectividad de la arquitectura queda directamente vinculada a la estructura del estado y al tipo de circuito ejecutado, lo cual resulta coherente con el análisis previo de compresibilidad.

9.4 Caché LRU de bloques descomprimidos


La descompresión selectiva sería insuficiente si cada bloque tuviera que recomprimirse y recuperarse nuevamente después de cada acceso. Para amortiguar ese costo, la arquitectura incorpora una caché temporal de bloques descomprimidos que actúa como conjunto de trabajo del simulador. Su función es conservar en memoria densa aquellos bloques accedidos recientemente, de modo que las operaciones sucesivas puedan reutilizarlos sin repetir el ciclo completo de recuperación.

La política de reemplazo adoptada es LRU (*Least Recently Used*). Bajo esta política,

cuando la caché alcanza su capacidad y es necesario incorporar un nuevo bloque, se expulsa el bloque cuyo último acceso sea el más antiguo. Esta elección se justifica porque la simulación suele exhibir localidad temporal: un bloque utilizado en una operación reciente tiene mayor probabilidad de volver a ser requerido en el corto plazo que uno que no ha sido accedido desde varias compuertas atrás.

La caché distingue además entre bloques limpios y bloques modificados. Si un bloque expulsado no ha sufrido cambios desde su recuperación, puede descartarse sin costo adicional. Si el bloque fue modificado, debe recomprimirse antes de abandonar la caché. Esta distinción evita escrituras innecesarias y convierte la caché en un mecanismo no solo de aceleración, sino también de control de sobrecarga. En términos arquitectónicos, la caché LRU cierra el vínculo entre compresión por bloques y acceso selectivo, ya que es el elemento que permite reutilizar materialización densa cuando el patrón de acceso presenta recurrencia.

Figura 4: Política de caché LRU para bloques



9.5 Flujo de compresión y descompresión

Sobre cada bloque, la compresión se concibe como un flujo de etapas reversibles. El bloque de amplitudes, representado como un arreglo contiguo en doble precisión, puede someterse primero a una transformación previa sobre su representación binaria, por ejemplo una variante de *shuffle* o *bitshuffle*, con el fin de exponer regularidades que favorezcan la compresión. A continuación, el bloque transformado se entrega al compresor sin pérdida, que genera la representación persistente utilizada por el backend de almacenamiento.

El proceso inverso ocurre únicamente cuando una operación requiere acceder al contenido del bloque. En ese momento, el bloque comprimido se recupera, se descomprime, se invierte la transformación previa y se reconstruye el arreglo denso de amplitudes listo para ser manipulado por la lógica del simulador. La reversibilidad de este flujo garantiza que el bloque obtenido tras la descompresión coincida exactamente con el bloque original antes de ser comprimido, condición indispensable para preservar igualdad exacta frente a la referencia no comprimida.

9.6 Compromisos y parámetros de diseño

La arquitectura propuesta presenta dos ventajas principales. La primera es que permite reducir la huella de memoria sin reconstruir de forma permanente el vector completo en su versión densa. La segunda es que introduce parámetros de control claros, como tamaño de bloque, capacidad de caché, política de reemplazo y configuración del compresor, que permiten ajustar la relación entre ahorro espacial y costo temporal según el patrón de acceso observado.

Estas mismas decisiones definen, sin embargo, un espacio de compromiso. Si los bloques son demasiado grandes, aumenta la compresibilidad potencial, pero también el costo de recuperar datos para operaciones locales. Si los bloques son demasiado pequeños, disminuye el costo de acceso, pero puede perderse oportunidad de compresión y aumentar la sobrecarga de metadatos. De forma similar, una caché muy reducida incrementa la tasa de fallos y el

número de descompresiones, mientras que una caché demasiado amplia amortigua accesos a costa de reservar más memoria densa activa.

La arquitectura también hereda una limitación más fundamental: su eficacia depende de la compresibilidad real del estado cuántico generado y del patrón de compuertas que lo recorre. Cuando el estado presenta alta regularidad o redundancia, el diseño puede convertir esa estructura en ahorro efectivo de memoria. En cambio, cuando el circuito genera amplitudes densas y poco compresibles o induce accesos dispersos sobre muchos bloques distintos, la ventaja espacial puede disminuir y la sobrecarga temporal hacerse más visible.

En síntesis, la propuesta delimita una arquitectura de almacenamiento comprimido que no modifica el modelo de simulación de estado completo, pero sí transforma la forma en que el vector de amplitudes reside y circula en memoria. Sobre esta base conceptual, el capítulo siguiente presenta la materialización concreta de estas decisiones en el esquema de almacenamiento comprimido implementado sobre TMFQSfullstate con apoyo de Blosc2.

10 Implementación del esquema de almacenamiento comprimido basado en Blosc

El desarrollo se apoya en una separación entre la interfaz lógica del registro cuántico y el backend responsable del almacenamiento del estado. Esta decisión permite mantener una interacción uniforme con el vector de amplitudes y, al mismo tiempo, introducir una realización comprimida capaz de administrar particionamiento por bloques, recuperación bajo demanda y persistencia de datos modificados. De esta forma, el simulador conserva su modelo de ejecución, pero delega en un backend especializado la manera en que las amplitudes residen y circulan en memoria.

10.1 Alcance de la implementación

La implementación se concentró en incorporar un backend de almacenamiento comprimido para el vector de estado dentro de TMFQSfullstate, manteniendo el modelo de simulación

de estado completo y preservando igualdad exacta respecto a la referencia no comprimida. El objetivo no fue rediseñar el simulador en su totalidad, sino intervenir la capa en la que se representan, recuperan y actualizan las amplitudes durante la ejecución.

Bajo este alcance, el desarrollo incluyó tres elementos principales. El primero fue una interfaz común para abstraer el almacenamiento del vector de estado y desacoplar el registro cuántico de una representación específica. El segundo fue un backend comprimido basado en Blosc2, encargado de la persistencia de bloques, la descompresión cuando el acceso lo requiere y la escritura de los bloques modificados. El tercero fue la integración de una estrategia de acceso y actualización compatible con la aplicación de compuertas sobre amplitudes distribuidas en uno o varios bloques.

La implementación buscó, en consecuencia, verificar que la solución propuesta podía insertarse en un simulador cuántico real con control suficiente sobre el uso de memoria, la sobrecarga temporal y la exactitud numérica. Los resultados de esa evaluación se presentan posteriormente; en esta sección interesa describir la organización del desarrollo y la forma en que sus componentes cooperan durante la simulación.

10.2 Realización del esquema de almacenamiento comprimido con Blosc


El punto de entrada del desarrollo es la clase `QuantumRegister`, que conserva la interfaz de uso del registro cuántico y delega las operaciones sobre el vector de estado en un backend que satisface la interfaz `IStateBackend`. Esta abstracción permite que el resto del simulador invoque operaciones como inicialización, carga de amplitudes, consulta, aplicación de compuertas o agrupación de operaciones sin depender de cómo se almacena internamente el estado.

Sobre esa interfaz se implementó `BloscStateBackend`, que constituye la realización concreta del almacenamiento comprimido. Esta clase encapsula la configuración del sistema, la cardinalidad del espacio de estados, la disposición de bloques, la caché de trabajo, los buffers auxiliares y la relación con el componente de compresión. Su responsabilidad principal es

traducir operaciones de alto nivel sobre el registro a secuencias concretas de adquisición de bloques, descompresión, modificación local y escritura de resultados.

La compresión efectiva se delega en `BloscCodec`, que implementa un wrapper de la API de `Blosc2` y centraliza operaciones como creación de la estructura comprimida, anexo de bloques, recuperación de fragmentos y actualización de contenido persistido. Esta encapsulación evita que el resto del backend dependa directamente de llamadas de bajo nivel a la biblioteca externa y facilita que la lógica de almacenamiento se mantenga separada de la lógica específica del código.

Figura 5: Diagrama de clases de la implementación del backend comprimido basado en `Blosc2`.



La figura 5 resume la organización general de esta implementación. En ella se observa la relación entre el registro cuántico, la interfaz de backend, la realización basada en Blosc, los componentes auxiliares de layout y caché, y los mecanismos de ejecución de compuertas.

En conjunto, esta organización permite que la compresión se integre como una responsabilidad propia de la capa de almacenamiento, y no como una operación aislada externa al flujo del simulador.

10.3 Disposición en bloques y mapeo del vector de estado

La partición del vector de estado se materializó mediante la clase `ChunkLayout`, encargada de establecer la correspondencia entre índices lógicos del arreglo de amplitudes y bloques físicos del backend comprimido. A través de esta clase se determina cuántos bloques componen el vector, cuántos estados almacena cada uno y cuál es la referencia local de una amplitud dentro del bloque al que pertenece.

Este mapeo cumple una función central dentro de la implementación. Por una parte, encapsula la granularidad del almacenamiento, evitando que otras partes del sistema deban reconstruir manualmente la relación entre estados y bloques. Por otra, asegura un tratamiento homogéneo tanto para bloques completos como para el bloque final, cuya cantidad efectiva de amplitudes puede diferir del tamaño nominal cuando el número total de estados no es múltiplo exacto del tamaño de bloque.

En términos operativos, el backend no trabaja con el vector completo como un único buffer comprimido, sino con una secuencia indexada de fragmentos. Cada consulta o modificación sobre una amplitud pasa primero por `ChunkLayout`, que resuelve el bloque correspondiente y la posición local del estado dentro de él. Gracias a esta mediación, el backend puede trabajar sobre una secuencia de fragmentos indexados y no sobre un arreglo monolítico, lo que simplifica la recuperación localizada y la escritura posterior de los datos.

10.4 Caché LRU de bloques descomprimidos

La gestión temporal de bloques materializados en memoria se implementó mediante la clase `ChunkCache`, cuya función es conservar un conjunto acotado de bloques descomprimidos recientemente utilizados. Su incorporación evita repetir ciclos completos de recuperación

cuando varias operaciones consecutivas requieren acceder a las mismas regiones del vector de estado.

La caché se configura según una capacidad determinada y administra la adquisición de bloques mediante una política LRU. Cuando un bloque es requerido, el backend consulta primero si ya se encuentra disponible en la caché. Si está presente, se reutiliza directamente su buffer descomprimido. Si no está presente, el bloque debe recuperarse desde el almacenamiento comprimido y, en caso de que la caché esté llena, expulsar el bloque menos recientemente utilizado. Si el bloque expulsado fue modificado desde su ingreso a la caché, se recompone su versión comprimida antes de liberar el buffer asociado.

La utilidad de esta implementación no se reduce a mejorar el rendimiento. La caché establece una forma explícita de administrar la memoria densa temporal del backend y determina qué parte del estado permanece materializada entre una compuerta y la siguiente. Por ello, su comportamiento influye directamente en la cantidad de descompresiones, en la frecuencia de escrituras y en la sobrecarga efectiva del sistema.

10.5 Acceso, actualización y ejecución de compuertas

La aplicación de compuertas sobre el backend comprimido se organizó de acuerdo con el patrón de acceso que cada operación induce sobre las amplitudes. En términos generales, la implementación distingue entre operaciones cuyos pares afectados pueden resolverse dentro de un mismo bloque y operaciones que involucran amplitudes distribuidas en bloques distintos. Esta distinción permite adaptar la ruta de ejecución al tipo de acceso requerido, en lugar de tratar todas las compuertas como si implicaran la materialización completa del vector.

Cuando la operación permanece dentro de un bloque, el backend adquiere ese bloque, opera sobre su buffer descomprimido y marca el contenido como modificado cuando corresponde. Cuando la compuerta involucra amplitudes ubicadas en bloques distintos, la ejecución requiere adquirir simultáneamente los bloques implicados y coordinar la actualización sobre ambos buffers. Esta lógica se articula a través del propio backend y de componentes auxi-

liares como `PairKernelExecutor` y `GateApplyEngine`, que separan rutas optimizadas para pares de amplitudes de una ruta más general para compuertas de aplicación genérica.

La implementación incluye además un mecanismo de agrupación operativa para delimitar el inicio y el cierre de lotes de trabajo. Este permite agrupar operaciones consecutivas y diferir ciertas escrituras mientras los bloques implicados permanecen activos. Así se reducen recomposiciones innecesarias y se mejora la interacción entre acceso al backend, reutilización de buffers y persistencia diferida de datos.

Desde el punto de vista funcional, esta organización hace posible que la lógica del simulador siga operando sobre amplitudes complejas y compuertas cuánticas del mismo modo que en una versión no comprimida, mientras la capa de almacenamiento resuelve de forma interna la recuperación, actualización y escritura de los bloques necesarios para cada paso de la simulación.

Figura 6: Flujo de ejecución para compuertas locales sobre un único bloque






Figura 7: Flujo de ejecución para compuertas que operan entre bloques

Figura 8: Flujo de persistencia diferida y escritura en backend comprimido

10.6 Optimización específica para Grover mediante parametrización reducida

Además del backend general basado en bloques comprimidos, el desarrollo incorporó una optimización específica para el algoritmo de Grover. Esta variante parte de la observación de que, en ciertos escenarios, la evolución del estado puede describirse mediante una parametrización reducida asociada a la estructura del algoritmo, sin necesidad de operar constantemente sobre el vector completo de amplitudes, su derivación matemática se puede encontrar en el apéndice A.

Su propósito no fue sustituir la implementación general, sino ofrecer una referencia complementaria para contrastar el efecto de una simplificación estructural específica frente al almacenamiento comprimido aplicable de manera general. Mientras el backend basado en

Blosc2 conserva una representación explícita del estado y modifica su forma de almacenamiento, la variante reducida aprovecha una regularidad particular de Grover y, por tanto, constituye una optimización especializada.

Esta inclusión resulta útil porque permite distinguir entre dos fuentes distintas de mejora: por un lado, las obtenidas mediante compresión sin pérdida sobre el vector de estado; por otro, las derivadas de una representación más compacta sustentada en la estructura del algoritmo. Sus resultados se presentan más adelante como comparación complementaria y no como reemplazo de la propuesta principal.

En conjunto, la implementación desarrollada organiza el almacenamiento comprimido como una combinación de interfaz, backend, layout de bloques, caché y mecanismos de ejecución de compuertas dentro de TMFQSfullstate. Esta estructura permite integrar Blosc2 en la ruta de simulación sin modificar el modelo de estado completo y prepara la base para la evaluación experimental presentada en el capítulo siguiente.

11 Evaluación experimental y resultados

Esta sección describe el diseño experimental empleado para evaluar la estrategia propuesta de almacenamiento comprimido. La evaluación se planteó como una comparación controlada entre almacenamiento no comprimido, compresión sin pérdida y compresión con pérdida controlada, usando cargas de trabajo con distinta compresibilidad, un mismo entorno de ejecución y criterios uniformes de medición, con el fin de analizar simultáneamente ahorro de memoria, sobrecarga temporal y exactitud numérica.

11.1 Diseño experimental

11.1.1 Estrategias comparadas

El experimento se organizó alrededor de tres estrategias de representación del vector de estado: una referencia sin compresión, la propuesta sin pérdida basada en Blosc y una alternativa con pérdida controlada basada en ZFP. Las tres se ejecutaron sobre los mismos circuitos, con iguales tamaños de qubits y bajo un procedimiento homogéneo de medición, de modo que las diferencias observadas pudieran atribuirse al esquema de almacenamiento y no a cambios en la carga o en la instrumentación.

11.1.2 Selección de cargas de trabajo

La evaluación se estructuró sobre dos familias de circuitos con comportamientos contrastantes en términos de compresibilidad: el algoritmo de búsqueda de Grover y la transformada cuántica de Fourier (QFT). Esta selección permitió evitar una evaluación sesgada hacia un único tipo de estado cuántico: Grover representa escenarios donde pueden emerger regularidades aprovechables por la compresión, mientras que QFT permite examinar casos en los que esa estructura se reduce o desaparece. Así, el diseño no solo cubre condiciones favorables para la propuesta, sino también situaciones menos propicias, necesarias para valorar su alcance real.

Casos evaluados para Grover En Grover se estudiaron dos variantes. La primera correspondió a un oráculo con objetivo único y se ejecutó con tres ubicaciones representativas del estado marcado: $N/8$, $N/2$ y $7N/8$, donde $N = 2^n$ es el tamaño del espacio de búsqueda. La segunda correspondió a un oráculo multiobjetivo con tres estados marcados distribuidos en esas mismas regiones. Con esta definición se buscó que los resultados no dependieran de una sola disposición de índices y, al mismo tiempo, observar si la posición de los elementos marcados introducía variaciones apreciables en memoria o tiempo de ejecución.

Casos evaluados para QFT En QFT se consideraron dos familias de entrada. La primera fue una superposición periódica, incluida por su estructura regular y repetitiva. La segunda fue una superposición de alta entropía con amplitudes de magnitud uniforme y fases aleatorias, definida como $a_y = e^{i\phi_y}/\sqrt{N}$ con $\phi_y \sim U[0, 2\pi)$ y semilla fija. Este contraste permitió enfrentar la propuesta tanto a estados con redundancia potencialmente explotable como a estados donde dicha redundancia es escasa, mientras que el uso de una semilla fija preservó la reproducibilidad del experimento.

11.1.3 Escala del experimento

La evaluación se realizó para 22, 23 y 24 qubits. Este rango permitió trabajar con instancias suficientemente grandes para que la memoria se convirtiera en una restricción relevante dentro de la capacidad disponible del entorno experimental, sin perder reproducibilidad ni comprometer la comparabilidad entre estrategias. Elegir varios tamaños dentro de ese intervalo también permitió observar cómo evolucionaban los efectos de la compresión a medida que crecía el vector de estado.

11.1.4 Entorno experimental e instrumentación

Todas las ejecuciones se realizaron en una plataforma experimental con Rocky Linux 10.1, procesador AMD Ryzen 7 5700X de 8 núcleos y 16 hilos, y 32 GiB de memoria RAM. La recolección de métricas se efectuó con los scripts de perfilado del repositorio del simulador,

que ejecutan los binarios experimentales y registran tiempo transcurrido y memoria máxima mediante `psrecord`. Se recurrió a `psrecord` porque, al operar como una herramienta externa al código instrumentado, permite observar el consumo de recursos del proceso sin introducir lógica adicional en la implementación evaluada. Con ello se buscó reducir la interferencia de la propia medición sobre el experimento y mantener un procedimiento uniforme para todas las estrategias comparadas.

11.1.5 Configuración de compresión

Las estrategias comprimidas se evaluaron con configuraciones fijas durante toda la evaluación, resumidas en la Tabla 7. Esta decisión se adoptó después de realizar pruebas previas de ajuste y respondió a un criterio de estabilidad metodológica: una vez seleccionadas las configuraciones que ofrecían el mejor compromiso entre memoria y tiempo para los casos de estudio, se conservaron sin cambios en toda la evaluación para evitar que la comparación quedara condicionada por un reajuste específico en cada experimento.

Tabla 7: Configuraciones de compresión utilizadas en toda la campaña experimental

Estrategia	Configuración
Blosc	<code>chunkStates = 32768, gateCacheSlots = 8, clevel = 1, nthreads = 4, compcode = 1, useShuffle = true.</code>
ZFP	Modo <code>FixedPrecision</code> , <code>precision = 40, chunkStates = 32768, gateCacheSlots = 8, nthreads = 4.</code>

11.1.6 Métricas de evaluación

Las métricas principales del estudio fueron el tiempo total de ejecución y la memoria máxima. Ambas se obtuvieron a partir de las trazas generadas por `psrecord`: el tiempo corresponde al último valor registrado en la columna *Elapsed time*, mientras que la memoria máxima corresponde al mayor valor de la columna *Real (MB)*. A partir de estas medidas se calcularon dos indicadores de lectura directa:

$$\text{Ahorro de memoria (\%)} = 100 \left(1 - \frac{M_{\text{comp}}}{M_{\text{ref}}} \right), \quad \text{Tiempo relativo (x)} = \frac{T_{\text{comp}}}{T_{\text{ref}}}.$$

En estas expresiones, M_{ref} y T_{ref} corresponden a la ejecución con almacenamiento no comprimido del mismo circuito y del mismo número de qubits. Un valor negativo en el ahorro de memoria indica que la estrategia evaluada consumió más memoria que la referencia, lo que permite identificar con claridad los casos en los que la compresión no alcanza a compensar sus propios costos auxiliares.

11.1.7 Verificación de exactitud numérica

La exactitud numérica se evaluó según la naturaleza de cada estrategia. En Blosc, al tratarse de una compresión sin pérdida, la validación consistió en exportar el vector completo de amplitudes de cada ejecución comprimida y compararlo amplitud por amplitud con la ejecución no comprimida de la misma instancia, con el fin de verificar igualdad exacta respecto a la referencia. En ZFP, esa misma comparación completa se empleó para medir el máximo error absoluto, ya que en este caso el interés no era demostrar igualdad exacta, sino cuantificar la desviación introducida por la compresión con pérdida.

11.1.8 Comparación complementaria para Grover

Además de la comparación principal entre almacenamiento no comprimido, Blosc y ZFP, en Grover se incorporó una evaluación complementaria con la variante de parametrización reducida descrita en la Sección 10.6. Esta comparación adicional permitió distinguir entre el beneficio derivado de comprimir el vector de estado y el que proviene de explotar directamente la estructura algebraica del algoritmo, por lo que en esa subsección complementaria la interpretación se concentra principalmente en memoria y tiempo de ejecución.

11.2 Resultados para Grover

Los resultados de Grover permiten examinar el comportamiento de las estrategias evaluadas en un escenario donde el vector de estado conserva regularidades que favorecen la compresión. Por esta razón, la discusión se organiza en torno a dos preguntas: cómo se comporta la relación entre ahorro de memoria y sobrecarga temporal frente a la referencia no comprimida, y en qué medida ese comportamiento se mantiene al pasar del caso estándar a la variante optimizada.

11.2.1 *Objetivo único*

Los resultados de la Tabla 8 muestran un patrón estable en los tres tamaños evaluados: la estrategia sin pérdida basada en Blosc reduce de forma pronunciada la memoria pico y lo hace con una sobrecarga temporal moderada en comparación con ZFP. Más que un efecto aislado de un tamaño particular, lo que se observa es una tendencia consistente a medida que crece el número de qubits: el ahorro de memoria de Blosc aumenta con la escala del problema, mientras que su costo temporal relativo permanece en un rango acotado cercano a cuatro o cinco veces la referencia. Esta combinación indica que, en Grover con objetivo único, la compresión sin pérdida no solo preserva exactitud, sino que mantiene una relación entre espacio y tiempo claramente más favorable que la alternativa con pérdida.

Otro aspecto relevante es que los promedios reportados sobre las posiciones $N/8$, $N/2$ y $7N/8$ no muestran indicios de una sensibilidad fuerte a la ubicación del objetivo. Esto sugiere que, al menos para las posiciones seleccionadas en el diseño experimental, el comportamiento agregado de memoria y tiempo está dominado por la estructura global del algoritmo más que por la elección puntual del índice marcado. Esa observación es importante para la lectura de la tabla porque permite interpretar los resultados como una propiedad del caso de estudio y no como un efecto ligado a una única instancia favorable.

Tabla 8: Grover con objetivo único: promedios sobre las posiciones $N/8$, $N/2$ y $7N/8$

Qubits	Estrategia	Mem. pico (MB)	Ahorro mem. (%)	Tiempo (s)	Tiempo rel. (x)	Error
22	Referencia	71.6	0.0	7.66	1.00	0
22	Blosc	15.9	77.8	37.16	4.85	0
22	ZFP	45.5	36.4	289.30	37.78	$1,61 \times 10^{-14}$
23	Referencia	135.5	0.0	24.82	1.00	0
23	Blosc	16.2	88.1	104.85	4.22	0
23	ZFP	78.2	42.3	801.01	32.27	$1,11 \times 10^{-14}$
24	Referencia	263.7	0.0	65.40	1.00	0
24	Blosc	17.1	93.5	279.33	4.27	0
24	ZFP	143.1	45.7	2274.03	34.77	$8,04 \times 10^{-15}$

11.2.2 Multiobjetivo

La Tabla 9 muestra que el paso de un objetivo único a tres estados marcados no altera de forma sustancial el patrón observado en Grover. Blosc conserva prácticamente los mismos niveles de ahorro de memoria y tiempos relativos muy próximos a los del caso anterior, mientras que ZFP mantiene una reducción de memoria más modesta y una penalización temporal mucho mayor. La continuidad de este comportamiento sugiere que, dentro del rango evaluado, el aumento en el número de objetivos modifica la instancia del problema sin cambiar el rasgo que resulta más relevante para la compresión: la presencia de una estructura del estado suficientemente regular para que la representación comprimida siga siendo ventajosa.

En los dos casos, la propuesta sin pérdida desplaza el compromiso entre memoria y tiempo hacia una zona intermedia: reduce de manera muy marcada la memoria requerida respecto a la referencia, pero sin incurrir en la penalización extrema que acompaña a ZFP. Esa estabilidad entre variantes fortalece la interpretación de que el beneficio observado no depende exclusivamente de una configuración particular del oráculo, sino de un comportamiento más general de Grover como carga favorable para la compresión sin pérdida.

Tabla 9: Grover multiobjetivo con tres estados marcados

Qubits	Estrategia	Mem. pico (MB)	Ahorro mem. (%)	Tiempo (s)	Tiempo rel. (x)	Error
22	Referencia	71.7	0.0	7.50	1.00	0
22	Blosc	15.9	77.8	36.43	4.86	0
22	ZFP	45.4	36.7	285.99	38.13	$1,61 \times 10^{-14}$
23	Referencia	135.6	0.0	24.98	1.00	0
23	Blosc	16.2	88.1	104.11	4.17	0
23	ZFP	78.2	42.3	827.17	33.12	$1,11 \times 10^{-14}$
24	Referencia	263.6	0.0	65.62	1.00	0
24	Blosc	17.1	93.4	278.25	4.24	0
24	ZFP	143.1	45.7	2278.80	34.73	$8,04 \times 10^{-15}$

11.2.3 Comparación complementaria con la variante optimizada

Las Tablas 10 y 11 muestran un resultado especialmente relevante para la proyección de este trabajo: cuando la ejecución de Grover se reorganiza de forma que disminuye la necesidad de materializar y actualizar repetidamente bloques del vector de estado, la compresión sin pérdida conserva casi el mismo beneficio espacial observado en la variante general, pero con una penalización temporal mucho más contenida. En particular, Blosc mantiene ahorros de memoria entre 87.0 % y 96.6 %, mientras que su tiempo relativo frente a la referencia cae a un intervalo aproximado entre 1.40x y 2.11x. Esta diferencia es significativa si se compara con la versión no optimizada, donde la sobrecarga temporal se ubicaba alrededor de cuatro veces la referencia.

Este comportamiento sugiere que, en el caso de Grover, una parte importante del costo temporal no proviene de la compresión en sí misma, sino del patrón de acceso al almacenamiento comprimido. Cuando la ejecución obliga a recuperar, descomprimir, modificar y recomprimir bloques con alta frecuencia, la ventaja espacial se obtiene a costa de una sobrecarga más marcada. En cambio, al reducir el número de accesos y evitar ciclos repetidos de compresión y descompresión sobre chunks que no necesitan ser materializados continuamente, la relación entre memoria y tiempo mejora de forma clara. En otras palabras, la variante

optimizada pone en evidencia que el verdadero cuello de botella no está únicamente en la tasa de compresión alcanzada, sino en la cantidad de transferencias y transformaciones que deben realizarse sobre los bloques durante la simulación. Esta interpretación es consistente con la arquitectura propuesta, en la que la sobrecarga efectiva depende del número de bloques activados, de la localidad del acceso y de la posibilidad de reutilizar buffers descomprimidos mediante caché.

Otro aspecto importante es que esta mejora se mantiene tanto en el caso de objetivo único como en el multiobjetivo. La cercanía entre los resultados de ambas tablas indica que la optimización no depende de una instancia particular del oráculo, sino de una propiedad más general: la posibilidad de explotar una representación más compacta del estado y un flujo de ejecución que disminuya las operaciones sobre memoria comprimida. Esto refuerza la idea de que, para algoritmos con estructura regular como Grover, la combinación de compresión sin pérdida y reducción del tráfico de memoria puede convertirse en una estrategia especialmente efectiva para ampliar la escala práctica de simulación.

Tabla 10: Variante optimizada de Grover con objetivo único

Qubits	Estrategia	Mem. pico (MB)	Ahorro mem. (%)	Tiempo (s)	Tiempo rel. (x)
22	Referencia	135.6	0.0	0.72	1.00
22	Blosc	17.6	87.0	1.01	1.40
22	ZFP	39.9	70.6	1.34	1.85
23	Referencia	263.6	0.0	0.91	1.00
23	Blosc	17.6	93.3	1.46	1.60
23	ZFP	65.0	75.4	2.10	2.31
24	Referencia	519.6	0.0	1.12	1.00
24	Blosc	18.2	96.5	2.36	2.11
24	ZFP	114.1	78.0	3.53	3.16

Tabla 11: Variante optimizada de Grover multiobjetivo

Qubits	Estrategia	Mem. pico (MB)	Ahorro mem. (%)	Tiempo (s)	Tiempo rel. (x)
22	Referencia	135.6	0.0	0.67	1.00
22	Blosc	16.9	87.6	1.01	1.52
22	ZFP	39.9	70.6	1.27	1.91
23	Referencia	263.7	0.0	0.81	1.00
23	Blosc	17.2	93.5	1.42	1.74
23	ZFP	65.0	75.3	2.04	2.51
24	Referencia	519.7	0.0	1.14	1.00
24	Blosc	17.7	96.6	2.38	2.10
24	ZFP	114.1	78.0	3.50	3.08

11.3 Resultados para QFT

Los resultados de QFT permiten examinar el comportamiento de las estrategias evaluadas en un escenario más sensible a la estructura de la entrada que Grover. Por esta razón, la discusión se organiza a partir del contraste entre dos regímenes claramente distintos: una superposición periódica, donde todavía aparecen regularidades aprovechables por la compresión, y una superposición de alta entropía, donde esa posibilidad se reduce de forma marcada.

11.3.1 Superposición periódica

Los resultados de la Tabla 12 muestran que, en la entrada periódica, la compresión sigue siendo favorable, aunque con un balance entre memoria y tiempo menos holgado que en Grover. Blosc reduce de manera consistente la memoria pico en los tres tamaños evaluados y mantiene tiempos relativos del mismo orden, lo que indica que la regularidad presente en el estado todavía puede explotarse sin que la sobrecarga temporal crezca de forma desproporcionada. Sin embargo, el comportamiento ya no reproduce el patrón especialmente ventajoso observado en Grover: aquí la reducción de memoria es más moderada y su evolución con el

número de qubits no es tan uniforme, lo que sugiere una dependencia más estrecha de la estructura concreta de la entrada.

La comparación con ZFP introduce un matiz importante. En esta familia de entrada, la compresión con pérdida consigue mayores ahorros de memoria que Blosc en todos los tamaños reportados, pero lo hace con tiempos relativos también más altos y con un error absoluto máximo del orden de 10^{-11} . La lectura relevante dentro de esta sección no es simplemente que una estrategia comprima más y otra preserve exactitud, sino que la tabla muestra dos compromisos distintos: ZFP empuja más lejos la reducción de memoria a costa de tiempo adicional y pérdida numérica, mientras que Blosc conserva un equilibrio más moderado entre ahorro espacial, sobrecarga temporal e igualdad exacta. En otras palabras, la superposición periódica no elimina la ventaja de la compresión sin pérdida, pero sí la sitúa en un terreno comparativo menos contundente que el de Grover.

También resulta significativo que la brecha temporal entre Blosc y ZFP se mantenga en los tres tamaños evaluados. Esto sugiere que, aun en un caso donde la compresión con pérdida obtiene una reducción espacial más agresiva, el costo adicional de esa estrategia no desaparece al aumentar la escala del problema. Por ello, en QFT con entrada periódica la discusión no se resuelve en términos de una estrategia universalmente superior, sino en función del criterio que se privilegie dentro del experimento: máxima reducción de memoria o mejor equilibrio entre memoria, tiempo y exactitud.

Tabla 12: QFT con superposición periódica

Qubits	Estrategia	Mem. pico (MB)	Ahorro mem. (%)	Tiempo (s)	Tiempo rel. (x)	Error
22	Referencia	73.6	0.0	0.44	1.00	0
22	Blosc	35.7	51.4	1.52	3.48	0
22	ZFP	19.0	74.2	2.52	5.75	$3,79 \times 10^{-11}$
23	Referencia	139.6	0.0	1.21	1.00	0
23	Blosc	34.5	75.3	3.17	2.61	0
23	ZFP	25.4	81.8	5.68	4.68	$3,79 \times 10^{-11}$
24	Referencia	271.6	0.0	2.75	1.00	0
24	Blosc	92.4	66.0	6.99	2.54	0
24	ZFP	45.6	83.2	12.10	4.41	$3,79 \times 10^{-11}$

11.3.2 Superposición de alta entropía

La Tabla 13 cambia de manera clara el sentido de la comparación. En esta familia de entrada, tanto Blosc como ZFP dejan de producir ahorro de memoria y pasan a incrementar el consumo respecto a la referencia no comprimida, mientras que el tiempo de ejecución también se eleva de forma pronunciada. Más que un deterioro cuantitativo aislado, lo que aparece es un cambio cualitativo en el comportamiento del experimento: la compresión deja de operar como una estrategia de reducción de recursos y empieza a añadir costos que la estructura del estado ya no permite compensar.

En este caso, la diferencia entre Blosc y ZFP no altera esa lectura general, aunque sí permite distinguir grados de desfavorabilidad. Blosc mantiene una penalización considerable, pero todavía muy inferior a la de ZFP tanto en memoria como en tiempo. ZFP, por su parte, combina ahorros negativos más pronunciados con tiempos relativos extremadamente altos, de modo que la admisión de pérdida numérica no se traduce aquí en una ventaja práctica. Así, la tabla no solo muestra que la compresión puede dejar de ser útil cuando desaparecen las regularidades del estado, sino también que la estrategia sin pérdida conserva un comportamiento comparativamente menos adverso que la alternativa con pérdida incluso en un escenario desfavorable.

Otro rasgo importante es que el empeoramiento no se corrige con el aumento de qubits; por el contrario, tiende a hacerse más visible en las instancias mayores. Esto refuerza la interpretación de que el problema no reside únicamente en una configuración puntual del experimento, sino en una incompatibilidad más profunda entre la alta entropía del estado de entrada y el tipo de redundancia que las estrategias evaluadas necesitan para resultar convenientes. En esta subsección, por tanto, la tabla funciona menos como evidencia de rendimiento y más como evidencia de límite: muestra hasta dónde deja de ser razonable esperar beneficios de una representación comprimida del vector de estado.

En conjunto, los resultados de QFT muestran un comportamiento internamente contrastado. Cuando la entrada conserva estructura periódica, la compresión todavía puede ofrecer una reducción útil de memoria, aunque con un compromiso entre espacio, tiempo y exactitud menos favorable que en Grover. Cuando la entrada presenta alta entropía, ese margen desaparece y la compresión deja de ser conveniente. Así, dentro del caso QFT, la utilidad de las estrategias evaluadas queda determinada de forma mucho más directa por la compresibilidad efectiva del estado de entrada.

Tabla 13: QFT con superposición de alta entropía

Qubits	Estrategia	Mem. pico (MB)	Ahorro mem. (%)	Tiempo (s)	Tiempo rel. (x)	Error
22	Referencia	71.6	0.0	0.77	1.00	0
22	Blosc	85.3	-19.0	9.67	12.52	0
22	ZFP	73.1	-2.1	79.52	103.01	$3,53 \times 10^{-11}$
23	Referencia	135.7	0.0	2.00	1.00	0
23	Blosc	152.2	-12.1	20.98	10.48	0
23	ZFP	187.6	-38.2	171.47	85.65	$2,82 \times 10^{-11}$
24	Referencia	263.6	0.0	4.33	1.00	0
24	Blosc	392.8	-49.0	44.30	10.24	0
24	ZFP	409.8	-55.5	376.40	87.03	$3,79 \times 10^{-11}$

11.4 Comparación global de estrategias

Tabla 14: Síntesis comparativa frente al almacenamiento no comprimido

Carga de trabajo	Blosc: ahorro (%)	Blosc: tiempo (x)	ZFP: ahorro (%)	ZFP: tiempo (x)	ZFP: error
Grover, objetivo único	77.8 a 93.5	4.22 a 4.85	36.4 a 45.7	32.27 a 37.78	$8,04 \times 10^{-15}$ a $1,61 \times 10^{-14}$
Grover, multiobjetivo	77.8 a 93.4	4.17 a 4.86	36.7 a 45.7	33.12 a 38.13	$8,04 \times 10^{-15}$ a $1,61 \times 10^{-14}$
QFT, superposición periódica	51.4 a 75.3	2.54 a 3.48	74.2 a 83.2	4.41 a 5.75	$3,79 \times 10^{-11}$
QFT, alta entropía	-49.0 a -12.1	10.24 a 12.52	-55.5 a -2.1	85.65 a 103.01	$2,82 \times 10^{-11}$ a $3,79 \times 10^{-11}$

En conjunto, la evidencia experimental delimita con claridad el alcance de la propuesta. La compresión sin pérdida del vector de estado es una alternativa viable cuando la memoria es la restricción dominante y el estado conserva regularidades aprovechables. No obstante, sus beneficios no son universales: dependen de la estructura concreta del estado y del patrón de acceso que induce el circuito. Bajo las condiciones evaluadas, Blosc emerge como la opción más robusta entre las estrategias comparadas, mientras que la compresión con pérdida basada en ZFP solo ofrece ventajas parciales y situacionales.

12 Conclusiones y trabajo futuro

12.1 Conclusiones

Los resultados obtenidos a lo largo del trabajo permiten afirmar que la compresión sin pérdida representa una alternativa válida para reducir la huella de memoria en simuladores cuánticos de estado completo sin alterar la exactitud numérica de la simulación. Su incorporación dentro del simulador mostró que este tipo de estrategias puede aplicarse de manera efectiva sin abandonar la representación completa del estado, lo que preserva el valor de estos simuladores como referencia precisa para el análisis y la validación de algoritmos cuánticos.

Al mismo tiempo, el comportamiento observado durante la evaluación dejó claro que el beneficio de la compresión no es uniforme. Su utilidad depende de la estructura del estado cuántico y del tipo de circuito que se ejecuta, de modo que existen escenarios en los que la reducción de memoria resulta favorable y otros en los que esa ventaja es más limitada. Más que una solución general para cualquier simulación, la compresión sin pérdida se perfila así como una estrategia especialmente adecuada cuando el estado conserva regularidades que pueden aprovecharse durante el almacenamiento.

En este sentido, uno de los aportes centrales del trabajo fue mostrar que el problema de memoria no se resuelve únicamente con la elección de una biblioteca de compresión, sino con una integración coherente entre particionamiento del vector, acceso selectivo y reutilización temporal de datos. La estrategia desarrollada permitió materializar esa idea en una implementación concreta y comprobar que la compresión puede incorporarse como parte de la gestión de memoria del simulador, y no solo como un mecanismo externo de almacenamiento.

En conjunto, el trabajo demuestra que la compresión sin pérdida puede ampliar la capacidad práctica de simulación exacta cuando la memoria constituye la restricción principal y el comportamiento del estado ofrece condiciones favorables para ello. Su principal alcance está en aportar una alternativa que conserva igualdad exacta respecto a la ejecución no

comprimida y que, por esa misma razón, resulta útil en contextos donde no es aceptable sustituir precisión por aproximación.

12.2 Trabajo futuro

Los resultados obtenidos abren varias líneas de trabajo orientadas a ampliar el alcance de la estrategia propuesta y a mejorar su desempeño en escenarios más exigentes. Una primera dirección consiste en extender la implementación hacia esquemas de paralelización que permitan distribuir de forma más eficiente tanto el almacenamiento como el procesamiento del vector de estado. En particular, el uso combinado de MPI y OpenMP permitiría explorar configuraciones de memoria distribuida y memoria compartida en las que la compresión por bloques no solo contribuya a reducir la huella de almacenamiento, sino también a hacer más viable la simulación en arquitecturas de mayor escala.

Otra línea de interés es la incorporación de mecanismos de análisis previo del circuito cuántico o de planificación de la ejecución. A partir de una lectura anticipada de la secuencia de compuertas, sería posible identificar patrones de acceso al vector de estado y reorganizar la ejecución para reducir la cantidad de accesos a los bloques comprimidos. En esa misma dirección, también podría estudiarse una disposición alternativa de las amplitudes dentro de los bloques, con el fin de agrupar componentes que tienden a ser accedidos conjuntamente y así disminuir la frecuencia de compresión y descompresión durante la simulación.

De manera complementaria, resulta prometedor estudiar estrategias con tamaños de bloque dinámicos. En lugar de mantener una partición fija para todo el vector de estado, podría definirse una organización adaptable que aproveche la relación entre tamaño del bloque, tasa de compresión y costo de acceso. Bajo este enfoque, las amplitudes o regiones del estado con accesos más frecuentes podrían almacenarse en bloques más pequeños, favoreciendo la rapidez de actualización, mientras que aquellas con menor actividad podrían mantenerse en bloques más grandes, orientados a mejorar la compresión global. Esta posibilidad abre la puerta a políticas de almacenamiento más flexibles y sensibles al comportamiento real de la

simulación.

Asimismo, sería valioso ampliar la comparación experimental tanto en estrategias de referencia como en tipos de circuitos evaluados. Por un lado, convendría contrastar la propuesta con otros enfoques de optimización de memoria, no solo basados en compresión, sino también en representaciones alternativas o esquemas híbridos. Por otro, sería pertinente incorporar algoritmos cuánticos adicionales y cargas de trabajo con estructuras más diversas, de modo que pueda caracterizarse con mayor precisión en qué clases de circuitos la compresión sin pérdida ofrece ventajas más consistentes.

Finalmente, una continuación natural de este trabajo consiste en profundizar en políticas adaptativas que permitan decidir, durante la ejecución, cuándo conviene comprimir, cómo particionar el estado y qué configuración utilizar según el comportamiento observado. Con ello, la compresión sin pérdida dejaría de operar como un esquema estático de almacenamiento y podría evolucionar hacia un componente dinámico de gestión de memoria, ajustado a las características de cada simulación.

A Derivación de la parametrización reducida de Grover

La idea central es que, bajo las hipótesis habituales del algoritmo, la evolución no necesita seguir de manera independiente las N amplitudes del vector de estado. Debido a la simetría entre estados marcados y no marcados, basta con describir la dinámica mediante dos parámetros: una amplitud común para los estados marcados y otra para los no marcados.

Sea $W \subseteq \{0, \dots, N-1\}$ el conjunto de estados marcados por el oráculo, con $M = |W|$. En la versión estándar del algoritmo, el estado inicial es la superposición uniforme

$$|s\rangle = \frac{1}{\sqrt{N}} \sum_{x=0}^{N-1} |x\rangle,$$

y el oráculo actúa cambiando el signo de las amplitudes asociadas a los estados de W .

Bajo estas condiciones, todos los estados marcados tienen inicialmente la misma amplitud, y lo mismo ocurre con todos los estados no marcados. Además, tanto el oráculo como el operador de difusión preservan esa simetría: el primero afecta por igual a todos los estados marcados, y el segundo transforma cada amplitud únicamente en función del promedio global. Por ello, durante toda la evolución ideal del algoritmo, las amplitudes pueden agruparse en solo dos clases:

$$a_x^{(t)} = \begin{cases} u_t, & x \in W, \\ v_t, & x \notin W, \end{cases}$$

donde u_t representa la amplitud común de los estados marcados en la iteración t , y v_t la amplitud común de los no marcados.

Esta misma idea puede expresarse en términos de una base reducida del subespacio relevante. Definiendo los vectores normalizados

$$|w\rangle = \frac{1}{\sqrt{M}} \sum_{x \in W} |x\rangle, \quad |r\rangle = \frac{1}{\sqrt{N-M}} \sum_{x \notin W} |x\rangle,$$

el estado inicial uniforme se descompone como

$$|s\rangle = \frac{1}{\sqrt{N}} \sum_{x=0}^{N-1} |x\rangle = \sqrt{\frac{M}{N}} |w\rangle + \sqrt{\frac{N-M}{N}} |r\rangle.$$

En consecuencia, la evolución ideal de Grover queda confinada al subespacio generado por $\{|w\rangle, |r\rangle\}$, y cualquier estado del algoritmo puede escribirse como

$$|\psi_t\rangle = \alpha_t |w\rangle + \beta_t |r\rangle.$$

La relación entre ambas representaciones es directa. Como $|w\rangle$ distribuye uniformemente la amplitud sobre los M estados marcados y $|r\rangle$ sobre los $N - M$ restantes, se tiene

$$u_t = \frac{\alpha_t}{\sqrt{M}}, \quad v_t = \frac{\beta_t}{\sqrt{N-M}}.$$

Por tanto, seguir la evolución en términos de (α_t, β_t) o en términos de (u_t, v_t) es equivalente.

Acción del oráculo

El oráculo de Grover cambia el signo de las amplitudes correspondientes a los estados marcados y deja intactas las demás. Por tanto, si antes del oráculo el estado está descrito por (u_t, v_t) , después del oráculo las amplitudes quedan como

$$u'_t = -u_t, \quad v'_t = v_t.$$

Acción del operador de difusión

El operador de difusión viene dado por

$$D = 2 |s\rangle\langle s| - I,$$

y puede interpretarse como una inversión de cada amplitud respecto al promedio global. Si μ_t denota el promedio de amplitud después de aplicar el oráculo, entonces la difusión transforma cada componente según la regla

$$x \mapsto 2\mu_t - x.$$

Después del oráculo, el promedio de amplitud es

$$\mu_t = \frac{1}{N} \left(\sum_{x \in W} (-u_t) + \sum_{x \notin W} v_t \right) = \frac{-Mu_t + (N - M)v_t}{N}.$$

Aplicando ahora la difusión:

Para un estado marcado, cuya amplitud después del oráculo es $-u_t$,

$$u_{t+1} = 2\mu_t - (-u_t) = 2\mu_t + u_t.$$

Sustituyendo μ_t ,

$$u_{t+1} = 2 \left(\frac{-Mu_t + (N - M)v_t}{N} \right) + u_t = \frac{N - 2M}{N} u_t + \frac{2(N - M)}{N} v_t.$$

Para un estado no marcado, cuya amplitud después del oráculo es v_t ,

$$v_{t+1} = 2\mu_t - v_t.$$

Sustituyendo nuevamente μ_t ,

$$v_{t+1} = 2 \left(\frac{-Mu_t + (N - M)v_t}{N} \right) - v_t = -\frac{2M}{N} u_t + \frac{N - 2M}{N} v_t.$$

En consecuencia, una iteración completa de Grover queda descrita por la recurrencia

$$\begin{bmatrix} u_{t+1} \\ v_{t+1} \end{bmatrix} = \begin{bmatrix} \frac{N-2M}{N} & \frac{2(N-M)}{N} \\ -\frac{2M}{N} & \frac{N-2M}{N} \end{bmatrix} \begin{bmatrix} u_t \\ v_t \end{bmatrix}.$$

Condiciones iniciales y reconstrucción del estado

Como el algoritmo parte de la superposición uniforme, en $t = 0$ todas las amplitudes son iguales a $1/\sqrt{N}$. Por tanto,

$$u_0 = v_0 = \frac{1}{\sqrt{N}}.$$

A partir de la recurrencia anterior, cada iteración puede resolverse actualizando únicamente los parámetros u_t y v_t , sin necesidad de aplicar el oráculo y la difusión sobre las N amplitudes del vector de estado. Si en algún momento se requiere reconstruir el estado completo, basta asignar

$$a_x^{(t)} = \begin{cases} u_t, & x \in W, \\ v_t, & x \notin W. \end{cases}$$

Alcance de la reducción

La parametrización reducida depende de una propiedad muy específica de Grover: la evolución preserva la igualdad de amplitud dentro de las clases “marcada” y “no marcada”. Esa propiedad se cumple cuando el algoritmo parte de la superposición uniforme y el oráculo solo introduce un cambio de fase sobre los estados marcados. Bajo estas hipótesis, la dinámica efectiva queda contenida en un subespacio de dimensión dos.

Referencias

- Blosc Development Team. (s.f.). *C-blosc2 documentation*. Descargado 2026-03-29, de <https://www.blosc.org/c-blosc2/>
- Boixo, S., Isakov, S. V., Smelyanskiy, V. N., y Neven, H. (2017). Simulation of low-depth quantum circuits as complex undirected graphical models. *arXiv preprint arXiv:1712.05384*. Descargado de <https://arxiv.org/abs/1712.05384>
- Burtscher, M., y Ratanaworabhan, P. (2009). Fpc: A high-speed compressor for double-precision floating-point data. *IEEE Transactions on Computers*, 58(1), 18–31. Descargado de <https://userweb.cs.txstate.edu/~mb92/papers/tc09.pdf> doi: 10.1109/TC.2008.131
- Chen, J., Zhang, F., Huang, C., Newman, M., y Shi, Y. (2018). *Classical simulation of intermediate-size quantum circuits*. Descargado de <https://arxiv.org/abs/1805.01450>
- Deutsch, D., y Jozsa, R. (1992). Rapid solution of problems by quantum computation. *Proceedings of the Royal Society of London. Series A: Mathematical and Physical Sciences*, 439(1907), 553–558. Descargado de <https://doi.org/10.1098/rspa.1992.0167> doi: 10.1098/rspa.1992.0167
- Díaz, G., Steffenel, L., Barrios, C., y Couturier, J. (2025). Memory management strategies for software quantum simulators. *Quantum Reports*, 7(3), 41. Descargado de <https://www.mdpi.com/2624-960X/7/3/41> doi: 10.3390/quantum7030041
- Díaz, G., Steffenel, L. A., Barrios, C. J., y Couturier, J.-F. (2024). How to build a software quantum simulator. *Preprints*. Descargado de <https://doi.org/10.20944/preprints202409.1497.v1> doi: 10.20944/preprints202409.1497.v1
- Díaz Toro, G. J. (2025). *Gestión de memoria en simuladores de computación cuántica de software* (Tesis doctoral, Universidad Industrial de Santander). Descargado 2025-05-13, de <https://noesis.uis.edu.co/items/357883df-3223-45b0-9848-f7681c5b0511>

- facebook/zstd contributors. (s.f.). *facebook/zstd: Zstandard - fast real-time compression algorithm*. Descargado 2026-01-20, de <https://github.com/facebook/zstd>
- Gheorghiu, V. (2018). Quantum++: A modern c++ quantum computing library. *PLOS ONE*, 13(12), e0208073. Descargado de <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0208073> doi: 10.1371/journal.pone.0208073
- Gilberto Díaz, Jorge Saul, Daniel González Buendía, y Javier Sarmiento. (2026). *buendiagon/tmfqsfullstate: v1.0.0*. Zenodo software release. Descargado de <https://doi.org/10.5281/zenodo.19268085> (Source code archive of the TMFQSfullstate simulator) doi: 10.5281/zenodo.19268085
- Google Quantum AI. (s.f.). *qsimcirq python reference*. Official documentation. Descargado 2026-03-27, de <https://quantumai.google/reference/python/qsimcirq>
- Grover, L. K. (1996). A fast quantum mechanical algorithm for database search. En *Proceedings of the twenty-eighth annual acm symposium on theory of computing* (pp. 212–219). Descargado de <https://dl.acm.org/doi/10.1145/237814.237866> doi: 10.1145/237814.237866
- Häner, T., y Steiger, D. S. (2017). 0.5 petabyte simulation of a 45-qubit quantum circuit. En *Proceedings of the international conference for high performance computing, networking, storage and analysis (sc)*. doi: 10.1145/3126908.3126947
- Huffman, N., Pavlichin, D., y Weissman, T. (2024). *Lossy compression for schrödinger-style quantum simulations*. Descargado de <https://arxiv.org/abs/2401.11088>
- Intel-QS project. (s.f.). *Intel quantum simulator (intel-qs) documentation*. ReadTheDocs. Descargado 2026-03-27, de <https://intel-qs.readthedocs.io/en/docs/getting-started.html>
- Jamalidinan, S., y Cheshmi, K. (2025). *Floating-point data transformation for lossless compression*. Descargado de <https://arxiv.org/abs/2506.18062> doi: 10.48550/arXiv.2506.18062
- Jaques, S., y Häner, T. (2021). *Leveraging state sparsity for more efficient quantum simu-*

- lations*. Descargado de <https://arxiv.org/abs/2105.01533>
- Jones, T., Brown, A., Bush, I., y Benjamin, S. C. (2019). QuEST and High Performance Simulation of Quantum Computers. *Sci. Rep.*, 9, 10736. doi: 10.1038/s41598-019-47174-9
- Lindstrom, P., y Isenburg, M. (2006). Fast and efficient compression of floating-point data. *IEEE Transactions on Visualization and Computer Graphics*, 12(5), 1245–1250. Descargado de <https://pubmed.ncbi.nlm.nih.gov/17080858/> doi: 10.1109/TVCG.2006.143
- lz4 contributors. (s.f.). *Github - lz4/lz4: Extremely fast compression algorithm*. Descargado 2026-01-20, de <https://github.com/lz4/lz4>
- Markov, I. L., y Shi, Y. (2008). Simulating quantum computation by contracting tensor networks. *SIAM Journal on Computing*, 38(3), 963–981. Descargado de <https://arxiv.org/abs/quant-ph/0511069> doi: 10.1137/050644756
- Masui, K., Amiri, M., Connor, L., Deng, M., Fandino, M., Hoefer, C., ... Vanderlinde, K. (2015). A compression scheme for radio data in high performance computing. *arXiv preprint arXiv:1503.00638*. Descargado de <https://arxiv.org/abs/1503.00638> (Describes the Bitshuffle filter and HDF5 plugin) doi: 10.48550/arXiv.1503.00638
- Miller, D. M., y Thornton, M. A. (2006). QMDD: A decision diagram structure for reversible and quantum circuits. En *Proceedings of the 36th international symposium on multiple-valued logic (ISMVL'06)* (p. 30). Descargado de <https://ieeexplore.ieee.org/document/1623982/> doi: 10.1109/ISMVL.2006.35
- Nielsen, M. A., y Chuang, I. L. (2010). *Quantum computation and quantum information* (10th Anniversary Edition ed.). Cambridge University Press.
- Pednault, E., Gunnels, J. A., Nannicini, G., Horesh, L., Magerlein, T., Solomonik, E., ... Wisnieff, R. (2017). *Pareto-efficient quantum circuit simulation using tensor contraction deferral*. Descargado de <https://arxiv.org/abs/1710.05867>
- Qiskit Development Team. (2025). *Qiskit aer documentation*. Official documentation. Des-

- cargado 2026-03-27, de <https://qiskit.github.io/qiskit-aer/>
- quantumlib contributors. (s.f.). *qsim: Fast c++ and python library for state-vector simulation of quantum circuits*. GitHub repository. Descargado 2026-03-27, de <https://github.com/quantumlib/qsim>
- QuEST-Kit contributors. (s.f.). *Quest: Quantum exact simulation toolkit*. GitHub repository. Descargado 2026-03-27, de <https://github.com/QuEST-Kit/QuEST>
- Simon, D. R. (1997). On the power of quantum computation. *SIAM Journal on Computing*, 26(5), 1474–1483. Descargado de <https://doi.org/10.1137/S0097539796298637> doi: 10.1137/S0097539796298637
- Szabłowski, P. J. (2021). Understanding mathematics of grover’s algorithm. *Quantum Information Processing*, 20(5), 182. Descargado de <https://doi.org/10.1007/s11128-021-03125-w> doi: 10.1007/s11128-021-03125-w
- Viamontes, G. F., Markov, I. L., y Hayes, J. P. (2003). Improving gate-level simulation of quantum circuits. *Quantum Information Processing*, 2(5), 347–380. Descargado de <https://deepblue.lib.umich.edu/handle/2027.42/45525> doi: 10.1023/B:QINP.0000022725.70000.4a
- Vidal, G. (2003). Efficient classical simulation of slightly entangled quantum computations. *Phys. Rev. Lett.*, 91(14), 147902. doi: 10.1103/PhysRevLett.91.147902
- Vinkhuijzen, L., Coopmans, T., Elkouss, D., Dunjko, V., y Laarman, A. (2023, septiembre). LIMDD: A Decision Diagram for Simulation of Quantum Computing Including Stabilizer States. *Quantum*, 7, 1108. Descargado de <https://quantum-journal.org/papers/q-2023-09-11-1108/> doi: 10.22331/q-2023-09-11-1108
- Wu, X.-C., Di, S., Cappello, F., Finkel, H., Alexeev, Y., y Chong, F. T. (2018). Amplitude-aware lossy compression for quantum circuit simulation. En *Proceedings of the 4th international workshop on data reduction for big scientific data (drbsd-4) at sc18*. IEEE. Descargado de https://sc18.supercomputing.org/proceedings/workshops/workshop_files/ws_drbsd112s1-file1.pdf

- Wu, X.-C., Di, S., Dasgupta, E. M., Cappello, F., Finkel, H., Alexeev, Y., y Chong, F. T. (2019). Full-state quantum circuit simulation by using data compression. En *Proceedings of the international conference for high performance computing, networking, storage and analysis (sc'19)*. IEEE/ACM. doi: 10.1145/3295500.3356155
- Zhang, B., Fang, B., Ye, F., Gu, Y., Tallent, N., Tan, G., y Tao, D. (2024). *Overcoming memory constraints in quantum circuit simulation with a high-fidelity compression framework*. Descargado de <https://arxiv.org/abs/2410.14088>
- zlib authors. (2022). *zlib technical details*. Descargado 2026-01-20, de https://zlib.net/zlib_tech.html
- Zstandard project. (s.f.). *Zstandard - real-time data compression algorithm*. Descargado 2026-01-20, de <https://facebook.github.io/zstd/>