

Optimización de la Gestión de Memoria en Simuladores Cuánticos mediante la Compresión de Datos sin pérdida de precisión

Trabajo de grado para optar por el título de Ingeniero de Sistemas.

Director

Luis A. Núñez

Codirector

PhD. Gilberto Javier Díaz Toro

Autores

Daniel Adrián González Buendía

Javier Andres Sarmiento Salazar

Universidad
Industrial de
Santander





Agenda

- 1 **Contexto y problemática**
- 2 **Estado del arte**
- 3 **Metodología y decisiones de base**
- 4 **Diseño de la Arquitectura**
- 5 **Evaluación y Resultados**



Contexto y problemática

Planteamiento del problema

- En simuladores tipo Schrodinger, cada qubit adicional duplica el tamaño del vector de estado: 2^n
- La memoria crece de forma exponencial y se vuelve la restricción dominante para simular circuitos más grandes.
- Se requiere una estrategia que reduzca memoria sin cambiar el modelo de simulación ni introducir error numérico.

Pregunta central

¿Cómo optimizar la gestión de memoria mediante compresión sin pérdida para lograr ahorro significativo, sobrecarga temporal razonable e igualdad exacta frente a la referencia no comprimida?

Objetivo general


Diseñar e implementar una estrategia eficiente de gestión de memoria en simuladores cuánticos basada en técnicas de compresión sin pérdida de precisión, con el fin de optimizar el uso de recursos computacionales sin comprometer la exactitud numérica de las simulaciones.




Objetivos específicos




1. Análisis de impacto




3. Desarrollo e integración



2. Diseño de estrategia



**4. Implementación y
evaluación**




**5. Comparación
de resultados**

Estado del arte

Estado del arte y brecha identificada


- Los simuladores Schrodinger ofrecen exactitud y generalidad, pero con alto costo de memoria. (Jones et al., 2019; Qiskit Development Team, 2025; Häner & Steiger, 2017)
- Alternativas como redes tensoriales o diagramas de decisión son útiles en escenarios estructurados, pero cambian el régimen de simulación. (Vidal, 2003; Viamontes et al., 2003; Chen et al., 2018)
- La compresión con pérdida logra más ahorro en algunos casos, a costa de introducir error numérico. (Wu et al., 2018; Zhang et al., 2025; Linstrom, 2014)

Simuladores Schrödinger




Exactitud: alta
Memoria: muy alta

Redes tensoriales




Exactitud: alta (en estructuras)
Memoria: moderada

Diagramas de decisión



Exactitud: alta (en estructuras)
Memoria: moderada

Compresión con pérdida



Exactitud: baja (con error)
Memoria: baja




Brecha identificada

Compresión sin pérdida integrada en la ejecución del simulador, con igualdad exacta y sobrecarga controlada.



Metodología y decisiones base

Metodología de la investigación





Selección del simulador cuántico base

Alternativas consideradas

QuEST / Intel-QS

Alto rendimiento en HPC (multihilo, GPU), pero arquitectura orientada a desempeño, dificulta intervenir el backend de memoria.

qsim

Buena separación entre componentes de simulación y manejo del state vector; base modular; dificultad para intervenir almacenamiento.

Quantum++

Biblioteca header-only, ligera y fácil de modificar, pero menor proyección de escalabilidad.

TMFQSfullstate

Prototipo diseñado para estudiar estrategias de representación y memoria; máxima facilidad de intervención.



Selección de la biblioteca de compresión

Alternativas consideradas

Blosc2

Contenedores particionados con pipeline de filtros (shuffle/bitshuffle) y codecs configurables; diseñada para datos numéricos en memoria.

Zstd

Generalista de alto rendimiento con amplio rango de compromiso velocidad/ratio; el particionamiento recae en la aplicación.

LZ4

Muy baja latencia de descompresión, ideal cuando el costo temporal domina; sin gestión interna de bloques.

zlib

Referencia madura y estable, pero sin especialización en arreglos científicos ni acceso por bloques.



Diseño de la Arquitectura




Diseño de la propuesta: Objetivos arquitectónicos

- **Preservar exactitud numérica:** flujo estrictamente reversible.
- **Reducir memoria:** evitar mantener el vector completo de forma densa permanentemente.
- **Mantener sobrecarga temporal razonable:** acceso localizado y reutilización temporal.


Decisión estructural

Separar representación lógica del estado y representación física en memoria mediante una capa de almacenamiento comprimido por bloques.

Arquitectura por bloques y acceso selectivo




Representación por bloques del vector de estado



Caché Least Recently Used (LRU)

- La caché LRU conserva bloques descomprimidos recientemente usados.
- Se distingue entre bloques limpios y sucios para controlar escrituras.
- Se recomprime al expulsar o al finalizar lotes de operación.



Persistencia diferida: cierre de ciclo



Si `[batchDepth == 0]`



persistencia inmediata

Si `[batchDepth > 0]`



persistencia diferida

Compromisos principales



Bloques grandes

Mayor potencial de compresión, pero con mayor costo de acceso local.



Bloques pequeños

Menor costo de acceso, pero menor compresibilidad y más metadatos.



Caché amplia

Mejor reutilización temporal, pero más memoria densa activa.



Caché reducida

Menos memoria temporal, pero más **miss** y descompresiones.


Más memoria



Menos memoria

Trade-off: tiempo

La arquitectura se define como un balance explícito entre ahorro de memoria y costo temporal.



Evaluación y resultados

Diseño experimental y métricas

Estrategias Comparadas

- Referencia sin compresión.
- Propuesta sin pérdida basada en Blosc.
- Referencia con pérdida controlada basada en ZFP.

Cargas de trabajo

- Grover (objetivo único y multiobjetivo).
- QFT (entrada periódica y alta entropía).

Métricas principales

Ahorro de memoria


$$\text{Ahorro de memoria (\%)} = 100 \left(1 - \frac{M_{\text{comp}}}{M_{\text{ref}}} \right)$$

Tiempo relativo

$$\text{Tiempo relativo (x)} = \frac{T_{\text{comp}}}{T_{\text{ref}}}$$


Resultados: Grover (escenario favorable)

Grover un objetivo: RAM maxima consumida




- Blosc alcanzó ahorros de memoria hasta 97.3% en 25 qubits
- Se preservó igualdad exacta frente a la referencia en todos los casos evaluados.
- La sobrecarga temporal relativa disminuyó al aumentar la escala.

Grover un objetivo: tiempo total






Compromiso tiempo-memoria: Grover un objetivo



Resultados: QFT periódica (escenario intermedio)


- En memoria, ZFP obtuvo mayor reducción e introdujo error acotado del orden de 10^{-11} .
- Blosc mostró mejor balance en tiempo y memoria.
- No existe dominancia única en todos los criterios.




Resultados: QFT alta entropía (escenario desfavorable)

- Blosc no logró ahorro de memoria positivo en este régimen.
- ZFP redujo memoria de forma moderada, con sobrecarga temporal muy alta.
- Se evidencia un límite estructural: la compresibilidad depende del estado cuántico generado.


QFT alta entropía: RAM máxima consumida



QFT alta entropía: tiempo total



Compromiso tiempo-memoria: QFT alta entropía





Contribuciones del trabajo

- 1 **Arquitectura de backend comprimido por bloques** con caché LRU, flujo reversible y rutas especializadas para compuertas.
- 2 **Implementación funcional** integrada en TMFQSfullstate, con interfaz desacoplada (IStateBackend).
- 3 **Evaluación comparativa** sin pérdida (Blosc) vs. con pérdida (ZFP) en tres regimenes de compresibilidad (Grover, QFT periódica, QFT alta entropía).
- 4 **Caracterización de límites:** se identificó que el beneficio depende de la estructura del estado, no solo de la escala.

Conclusiones

1




Compresión sin
pérdida y exactitud
numérica garantizada.

2




Ahorro de memoria con
bloques, descompresión
selectiva y caché LRU.

3



Mejor desempeño en
estados de alta
regularidad (Grover).

4



En alta entropía, el
beneficio disminuye.

5



Se cumplieron los
cinco objetivos
específicos.



No es una mejora universal,
sino una alternativa exacta y sólida para
regímenes de simulación con redundancia explotable.

Trabajo futuro

1



Políticas adaptativas.

2



Análisis previo del
circuito.

3




Tamaños de bloques
dinámicos.

4




Más algoritmos,
estrategias y cargas de
trabajo.

5



Escenarios híbridos
(MPI + OpenMP).



Gracias por su atención

Preguntas